REPUBLIQUE DU SENEGAL

Un peuple, Un But, Une foi

MINISTERE DE L'ECONOMIE DU PLAN ET DE LA COOPERATION

Agence Nationale de la Statistique et de la Démographie

École Nationale de la Statistique et de l'Analyse Économique

****

Projet de modèle de durée :

Analyse de survie des patients atteints du cancer de l'estomac

Effectué par :

Samson Koffi AWOUTO

Elève Ingénieur statisticien économiste en ISE3

Sous la supervision de

Dr Aba DIIOP

Professeur à l'Université
Alioune DIOP, Département de
Mathématiques

Février 2026

Table des matières

Introduction **3**

Présentation des données **3**

Analyse de la Qualité des Données **6**

1 Estimer la fonction de survie globale **6**

2 Estimer la fonction de survie pour les hommes et pour les femmes **7**

3 Comparer les deux fonctions de survie (hommes et femmes) **7**
3.1 Comparaison Théorique (Test du Log-Rank) 7
3.2 Comparaison Graphique 8

4 Estimer la fonction de survie pour les différents types de traitement **9**

5 Comparer les quatre fonctions de survie (pour les différents types de traitement) **10**

6 Décomposer la variable « AGE » en trois classes **11**

7 Estimer la fonction de survie pour les différentes classes d'âge obtenues **13**

8 Comparer les trois fonctions de survie (pour les différentes classes d'âge) **14**

9 Estimer la fonction de hasard instantané **15**

10 Ajustement du Modèle de Cox **17**
10.1 Préparation et Recodage des Variables 17
10.1.1 Traitement : Analyse des 4 modalités 17
10.1.2 Variables Binaires : Gestion des occurrences multiples 17
10.2 Estimation du Modèle Complet 18
10.3 Sélection de Variables (Méthode Descendante) 21
10.4 Test des Interactions : 23
10.5 Présentation et Interprétation du Modèle Final 24
10.5.1 Visualisation (Forest Plot) 25
10.5.2 Interprétation Clinique des Résultats Ajustés 26

11 Validation du Modèle (Analyse des Résidus) **27**
11.1 Test de l'Hypothèse des Risques Proportionnels (Résidus de Schoenfeld) 27
11.2 Linéarité des Variables Continues (Résidus de Martingale) 29
11.3 Stratégie de Stratification (Piste d'amélioration) 29

12 Conclusion Générale **31**

Introduction

Ce projet d'analyse explore les déterminants de survie chez 200 patients traités pour un cancer de l'estomac. L'approche statistique combine des méthodes non paramétriques pour décrire la survie globale et comparée, et des modèles semi-paramétriques de Cox pour évaluer l'impact ajusté des facteurs de risque.

Présentation des données

Une analyse descriptive exhaustive des 200 patients inclus dans l'étude est présentée ci-dessous, distinguant les variables quantitatives et qualitatives. Cette étape est cruciale pour comprendre la structure de la cohorte avant toute modélisation.

```r
# Statistiques descriptives des variables quantitatives
vars_quanti <- df[, c("AGE", "DureeSurvieJr", "DuréeSymptomMois")]
stats_quanti <- data.frame(
    Variable = c("Âge (années)", "Durée de suivi (jours)", "Durée symptômes
     ↪  (mois)"),
    Min = sapply(vars_quanti, min, na.rm = TRUE),
    Q1 = sapply(vars_quanti, quantile, probs = 0.25, na.rm = TRUE),
    Mediane = sapply(vars_quanti, median, na.rm = TRUE),
    Moyenne = sapply(vars_quanti, mean, na.rm = TRUE),
    Q3 = sapply(vars_quanti, quantile, probs = 0.75, na.rm = TRUE),
    Max = sapply(vars_quanti, max, na.rm = TRUE),
    SD = sapply(vars_quanti, sd, na.rm = TRUE)
)
colnames(stats_quanti) <- c("Variable", "Min", "Q1", "Médiane", "Moyenne", "Q3",
 ↪  "Max", "Écart-type")

kable(stats_quanti, digits = 1, booktabs = TRUE, caption = "Variables
 ↪  Quantitatives : Statistiques descriptives") %>%
    kable_styling(latex_options = c("striped", "hold_position", "scale_down"),
     ↪  font_size = 10) %>%
    column_spec(1, bold = TRUE, width = "4cm")
```

Table 1 : Variables Quantitatives : Statistiques descriptives

	Variable	Min	Q1	Médiane	Moyenne	Q3	Max	Écart-type
AGE	Âge (années)	26	46.0	53.5	53.5	60.0	82	11.1
DureeSurvieJr	Durée de suivi (jours)	2	82.5	3600.0	2097.4	3600.0	3600	1724.6
DuréeSymptomMois	Durée symptômes (mois)	1	2.0	4.0	7.3	11.2	24	7.3

```r
# Statistiques descriptives des variables qualitatives
# Création manuelle d'un data.frame structuré pour kableExtra
qual_data_list <- list(
    list(var = "Sexe", col = df$SEXE),
    list(var = "Traitement", col = df$Traitement),
    list(var = "Statut Vital", col = factor(df$DECES, labels = c("Vivant/Censuré",
     ↪  "Décédé"))),
```

```r
    list(var = "Antécédents Personnels", col = df$AntPersoMed),
    list(var = "Antécédents Familiaux", col = df$AntFamil),
    list(var = "Mode de Vie (Tabac/Alcool)", col = df$AntModVie),
    list(var = "Autres Comorbidités", col = df$AntFactComorb),
    list(var = "Type Adénocarcinome", col = df$AdénocarciDifference),
    list(var = "Métastases (Scanner)", col = df$Scan.Metastases),
    list(var = "Motif: Epigastralgies", col = factor(df$MotifCons.Epigastralgies,
     ↪  levels = c(0, 1), labels = c("Non", "Oui"))),
    list(var = "Motif: Vomissements", col = factor(df$MotifCons.Vomissements,
     ↪  levels = c(0, 1), labels = c("Non", "Oui"))),
    list(var = "Motif: Masse Abdominale", col = factor(df$`MotifCons.Masse
     ↪  abdominale`, levels = c(0, 1), labels = c("Non", "Oui"))),
    list(var = "Motif: Constipation", col = factor(df$MotifCons.Constipation,
     ↪  levels = c(0, 1), labels = c("Non", "Oui")))
)

results <- do.call(rbind, lapply(qual_data_list, function(item) {
    t <- table(item$col, useNA = "ifany")
    p <- prop.table(t) * 100
    data.frame(Variable = item$var, Modalite = names(t), Effectif = as.numeric(t),
     ↪  Pourcentage = sprintf("%.1f%%", p))
}))

# Tableau final sans la colonne Variable répétée, géré par pack_rows
tab_final <- results[, -1]
colnames(tab_final) <- c("Modalité", "Effectif (N)", "Fréquence (%)")

k <- kable(tab_final, booktabs = TRUE, row.names = FALSE, caption = "Variables
 ↪  Qualitatives : Répartition des effectifs") %>%
    kable_styling(latex_options = c("striped", "hold_position"), font_size = 9)
     ↪  %>%
    column_spec(1, width = "5cm") %>%
    column_spec(2:3, width = "2.5cm", latex_valign = "m")

# Ajout dynamique des pack_rows
rle_res <- rle(as.character(results$Variable))
start_row <- 1
for (i in 1:length(rle_res$values)) {
    k <- pack_rows(k, rle_res$values[i], start_row, start_row + rle_res$lengths[i]
 ↪  - 1)
    start_row <- start_row + rle_res$lengths[i]
}
k
```

Table 2 : Variables Qualitatives : Répartition des effectifs

Modalité	Effectif (N)	Fréquence (%)
Sexe		

Homme	99	49.5%
Femme	101	50.5%
Traitement		
Traitement 0	9	4.5%
Traitement 1	129	64.5%
Traitement 2	1	0.5%
Traitement 3	61	30.5%
Statut Vital		
Vivant/Censuré	102	51.0%
Décédé	98	49.0%
Antécédents Personnels		
Non	142	71.0%
Oui	58	29.0%
Antécédents Familiaux		
Non	178	89.0%
Oui	22	11.0%
Mode de Vie (Tabac/Alcool)		
Non	102	51.0%
Oui	98	49.0%
Autres Comorbidités		
Non	103	51.5%
Oui	97	48.5%
Type Adénocarcinome		
Type 1	26	13.0%
Type 2	51	25.5%
Type 3	64	32.0%
Type 4	59	29.5%
Métastases (Scanner)		
Absence	146	73.0%
Présence	54	27.0%
Motif : Epigastralgies		
Non	28	14.0%
Oui	172	86.0%
Motif : Vomissements		
Non	18	9.0%
Oui	182	91.0%
Motif : Masse Abdominale		
Non	192	96.0%
Oui	8	4.0%
Motif : Constipation		
Non	185	92.5%
Oui	15	7.5%

L'échantillon présente une distribution équilibrée par sexe (49.5% Hommes / 50.5% Femmes). L'âge moyen est de 53.5 ans. La durée moyenne des symptômes avant diagnostic est de 7.3 mois. Le traitement chirurgical est prédominant (64.5%). Concernant les facteurs cliniques, on note la présence de métastases au scanner chez une partie des patients et une variabilité dans le type histologique (Adénocarcinome).

Analyse de la Qualité des Données

Avant toute modélisation, il est crucial de vérifier la complétude des données, car les modèles de survie (Cox) requièrent par défaut des observations complètes. L'analyse des valeurs manquantes (`NA`) sur l'ensemble des variables d'intérêt (Âge, Sexe, Traitement, Antécédents, Motifs, Décès, Durée de survie) révèle un taux de remplissage de **100%**. Aucune imputation n'est nécessaire. Ce point fort méthodologique garantit que nos résultats ne seront pas biaisés par une sélection de cas incomplets.

1. Estimer la fonction de survie globale

L'analyse débute par la modélisation de la survie globale de la cohorte via l'estimateur de Kaplan-Meier, permettant de visualiser la cinétique des décès au cours du temps.

```
fit_global <- survfit(survie ~ 1, data = df)
ggsurvplot(fit_global, data = df, conf.int = TRUE, risk.table = TRUE, palette =
↪  "blue", ggtheme = theme_classic(), legend = "none", xlab = "Temps (jours)",
↪  ylab = "Probabilité de survie S(t)", title = "")
```

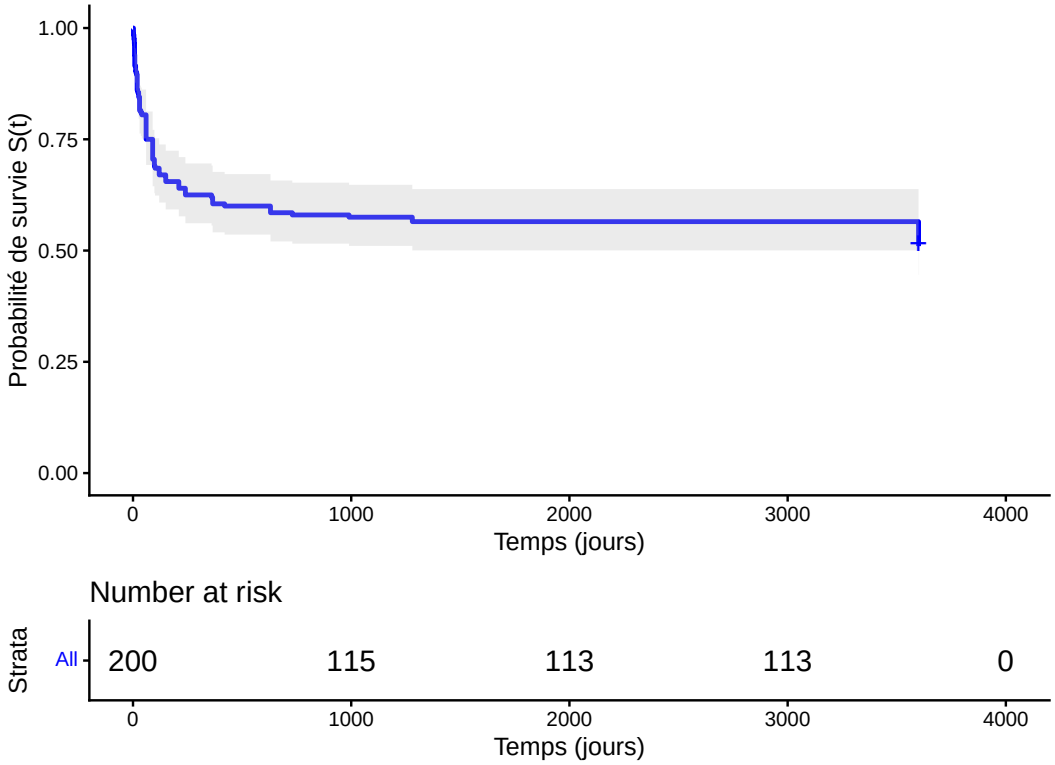

La courbe de survie met en évidence une mortalité précoce importante, avec une probabilité de survie chutant à 60% dès la première année, suivie d'une stabilisation remarquable où la courbe tend vers un plateau. La médiane de survie n'est pas atteinte au terme des 10 ans de suivi, indiquant que la majorité des patients survit durablement après la phase critique initiale. Ce profil suggère une population hétérogène composée de cas très sévères à décès rapide et de patients répondeurs vivant avec la maladie sur le long terme.

2. Estimer la fonction de survie pour les hommes et pour les femmes

Nous estimons les fonctions de survie séparément pour chaque sexe à l'aide de l'estimateur de Kaplan-Meier afin de dégager une première tendance descriptive.

```r
# Estimation de la fonction de survie par sexe (Kaplan-Meier)
fit_sexe <- survfit(survie ~ SEXE, data = df)
print(fit_sexe)
```

```
## Call: survfit(formula = survie ~ SEXE, data = df)
##
##              n events median 0.95LCL 0.95UCL
## SEXE=Homme  99     44     NA     365      NA
## SEXE=Femme 101     54   3600    1280      NA
```

Les estimations ponctuelles décrivent deux groupes aux effectifs comparables (99 hommes et 101 femmes) avec un nombre de décès respectivement de 44 et 54. Bien que la médiane estimée pour les femmes (3600 jours) puisse paraître différente de celle des hommes (non atteinte), les taux de survie observés restent globalement du même ordre de grandeur, dépassant 50% en fin de suivi pour les deux groupes.

3. Comparer les deux fonctions de survie (hommes et femmes)

Pour valider statistiquement l'impression descriptive, nous procédons à une double comparaison : graphique et théorique.

3.1 Comparaison Théorique (Test du Log-Rank)

Le test du **Log-Rank** est un test non-paramétrique qui compare les distributions de survie de deux échantillons. Il repose sur le calcul, à chaque instant de décès t_j, de l'écart entre le nombre de décès observés (O_{ij}) et le nombre de décès attendus (E_{ij}) sous l'hypothèse nulle H_0 (égalité des fonctions de survie $S_1(t) = S_2(t)$).

La statistique de test suit asymptotiquement une loi du χ^2 à 1 degré de liberté :

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}$$

Si la p-value associée est inférieure au seuil de signification $\alpha = 0.05$, on rejette H_0 et on conclut à une différence significative de survie entre les groupes.

```r
# Test du Log-Rank pour l'égalité des courbes (H0: S1(t) = S2(t))
test_sexe <- survdiff(survie ~ SEXE, data = df)
print(test_sexe)
```

```
## Call:
## survdiff(formula = survie ~ SEXE, data = df)
##
##              N Observed Expected (O-E)^2/E (O-E)^2/V
```

```
## SEXE=Homme  99       44     47.4     0.241     0.483
## SEXE=Femme 101       54     50.6     0.226     0.483
##
##  Chisq= 0.5  on 1 degrees of freedom, p= 0.5
```

Interprétation du test : Le test du log-rank affiche une p-value de 0.487. Cette valeur étant très largement supérieure au seuil de 5%, **nous ne pouvons pas rejeter l'hypothèse nulle**. Statistiquement, il n'y a pas de preuve que le sexe influence la survie dans cette cohorte. Les différences d'effectifs de décès observés (44 vs 54) sont conformes aux fluctuations aléatoires attendues sous l'hypothèse d'égalité.

3.2 Comparaison Graphique

Nous superposons les courbes de Kaplan-Meier avec leurs intervalles de confiance pour visualiser cette absence de différence.

```r
# Comparaison graphique
ggsurvplot(fit_sexe,
    data = df,
    pval = TRUE,
    conf.int = TRUE,
    risk.table = TRUE,
    palette = c("blue", "red"),
    ggtheme = theme_classic(),
    legend.title = "Sexe",
    xlab = "Temps (jours)",
    legend.labs = c("Homme", "Femme")
)
```

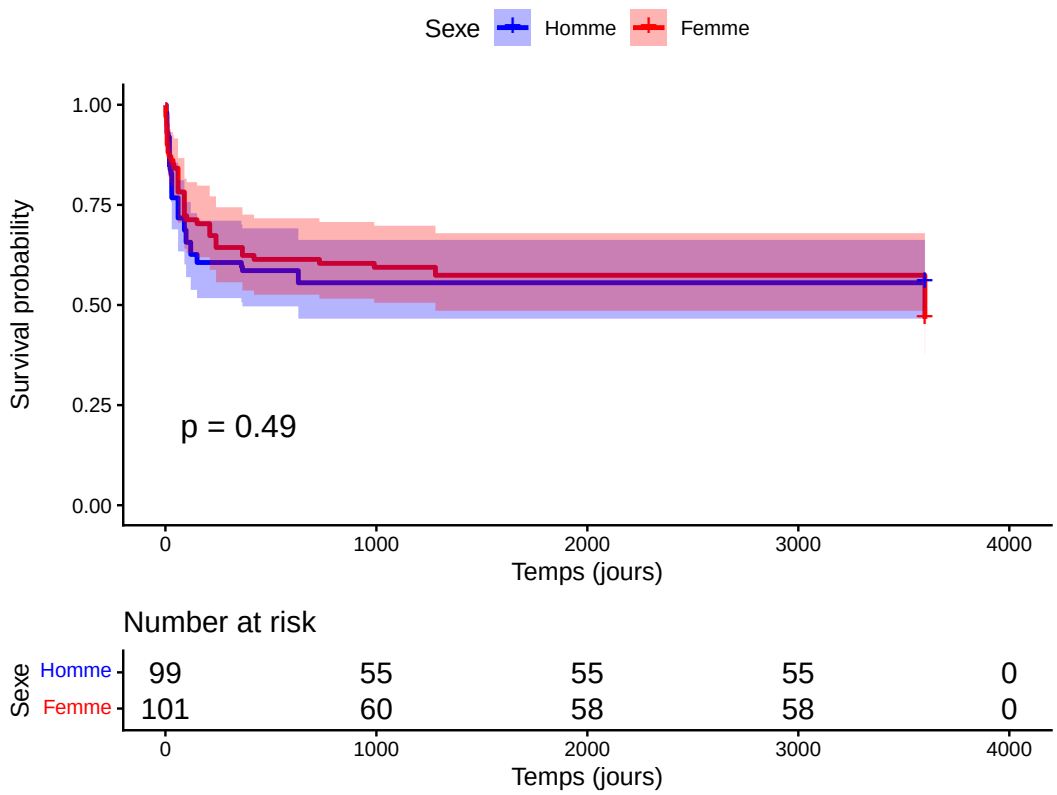

L'absence de différence statistiquement significative est confirmée visuellement par le chevauchement important des intervalles de confiance sur toute la durée du suivi. Les deux courbes s'entrecroisent à plusieurs reprises, ne montrant aucune tendance systématique en faveur d'un groupe. Le sexe n'apparaît donc pas comme un facteur pronostique discriminant dans cette analyse univariée.

4. Estimer la fonction de survie pour les différents types de traitement

Nous analysons maintenant l'impact du type de traitement reçu sur la survie des patients. Quatre modalités thérapeutiques sont distinguées ab initio : Traitement 1, Traitement 3, Traitement 2 et Traitement 0.

```r
# Estimation par type de traitement (4 modalités) - Voir Note Méthodologique
fit_trait <- survfit(survie ~ Traitement, data = df)
print(fit_trait)
```

```
## Call: survfit(formula = survie ~ Traitement, data = df)
##
##                          n events median 0.95LCL 0.95UCL
## Traitement=Traitement 0   9      9     19      19      NA
## Traitement=Traitement 1 129     62     NA    3600      NA
## Traitement=Traitement 2   1      1     26      NA      NA
## Traitement=Traitement 3  61     26     NA     990      NA
```

L'examen de la sortie R révèle plusieurs points cruciaux pour l'interprétation. Premièrement, la

présence de nombreuses valeurs `NA` dans les colonnes `median` et `0.95UCL` pour les groupes Traitement 1 et Traitement 3 n'est pas une erreur, mais un signal clinique très positif : cela signifie que la médiane de survie n'est pas atteinte (plus de 50% des patients sont encore en vie à la fin du suivi), confirmant l'efficacité de ces traitements.

Deuxièmement, on note un déséquilibre extrême des effectifs : le groupe "Traitement 2" ne compte qu'un seul patient (n=1), ce qui rend toute estimation de variance impossible (NA pour les IC) et sa courbe de survie non informative. Le groupe "Traitement 0" (n=9) présente quant à lui une médiane très basse de 19 jours, illustrant la gravité de la maladie en l'absence de thérapie active majeure.

5. Comparer les quatre fonctions de survie (pour les différents types de traitement)

Pour réaliser une comparaison statistique valide par le test du log-rank, nous devons gérer le cas unique du patient sous radiothérapie.

Analyse des 4 groupes de traitement : Conformément à la demande, nous analysons les 4 groupes distincts.

```r
# Test du Log-Rank sur les 4 groupes (H0: S1=S2=S3=S4)
test_trait <- survdiff(survie ~ Traitement, data = df)
print(test_trait)
```

```
## Call:
## survdiff(formula = survie ~ Traitement, data = df)
##
##                            N Observed Expected (O-E)^2/E
## Traitement=Traitement 0   9        9    1.339   43.8199
## Traitement=Traitement 1 129       62   63.606    0.0405
## Traitement=Traitement 2   1        1    0.167    4.1712
## Traitement=Traitement 3  61       26   32.889    1.4428
##                          (O-E)^2/V
## Traitement=Traitement 0     46.69
## Traitement=Traitement 1      0.12
## Traitement=Traitement 2      4.27
## Traitement=Traitement 3      2.25
##
##  Chisq= 52.1  on 3 degrees of freedom, p= 3e-11
```

```r
# Comparaison graphique
ggsurvplot(fit_trait,
    data = df,
    pval = TRUE,
    risk.table = TRUE,
    palette = c("red", "blue", "purple", "green"),
    ggtheme = theme_classic(),
    legend.title = "Traitement",
    xlab = "Temps (jours)",
```

```
    legend.labs = levels(df$Traitement)
)
```

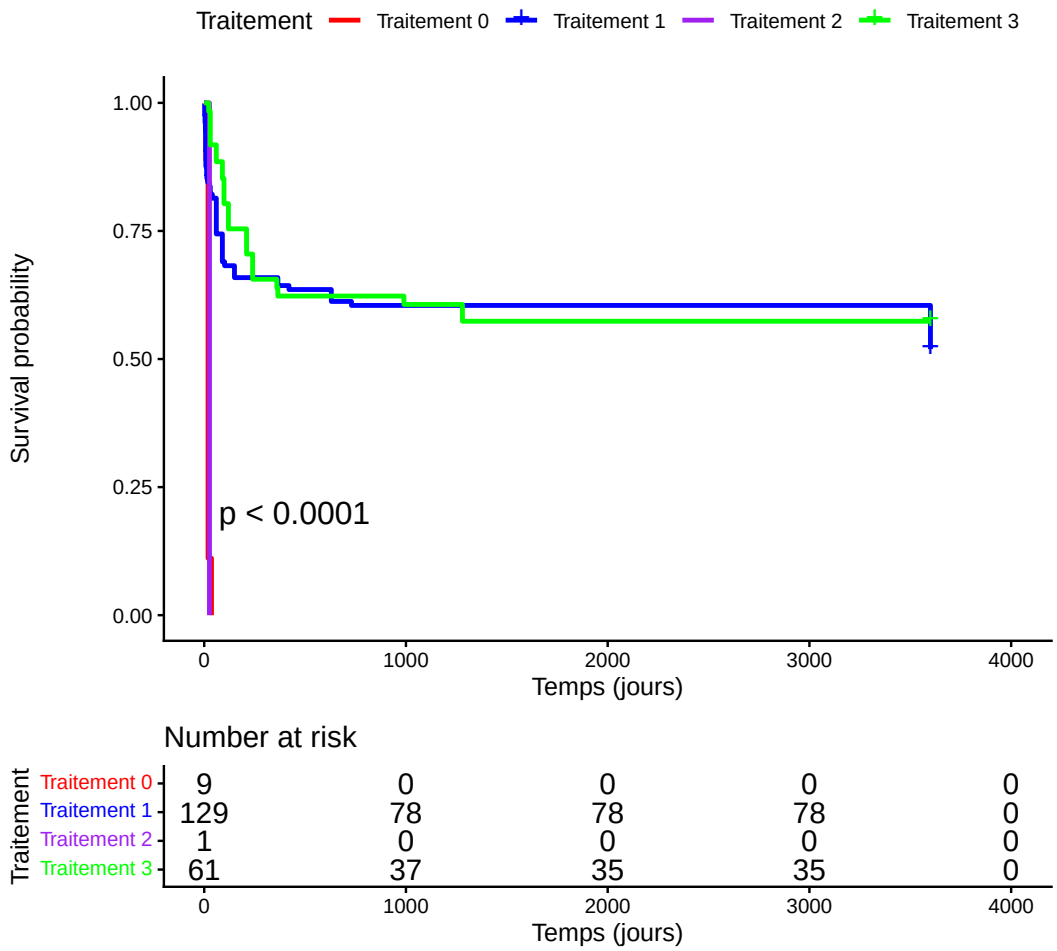

Le test du log-rank compare les courbes de survie des quatre groupes avec une p-value de 3e-11, ce qui est extrêmement significatif ($p < 0.05$). Nous rejetons donc l'hypothèse nulle d'égalité des fonctions de survie : les différences observées entre les groupes de traitement sont hautement significatives. Graphiquement, la distinction entre les traitements actifs (1 et 3) et le Traitement 0 (ou traitement 2) reste marquée, confirmant l'importance cruciale du traitement sur la survie.

6. Décomposer la variable « AGE » en trois classes

L'âge étant une variable continue, sa transformation en classes permet de simplifier l'analyse et de détecter des seuils de risque. Pour garantir une comparaison statistique robuste et éviter tout choix arbitraire de seuils, nous adoptons une méthodologie rigoureuse basée sur les **tertiles**. Cette approche divise la distribution des âges en trois groupes d'effectifs égaux, assurant ainsi une puissance statistique comparable entre les classes.

```
# Calcul des tertiles pour définir les bornes exactes
tertiles <- quantile(df$AGE, probs = c(0, 1 / 3, 2 / 3, 1), na.rm = TRUE)
```

```r
# Création explicite des classes avec bornes
df$AGE_CAT <- cut(df$AGE, breaks = tertiles, include.lowest = TRUE, labels =
 ↪  c("Jeunes [26-48]", "Moyens ]48-57]", "Agés ]57-82]"))

# Création du tableau de fréquences détaillé
freq_age <- data.frame(
    Classe = levels(df$AGE_CAT),
    Effectif = as.numeric(table(df$AGE_CAT)),
    Frequence = as.numeric(prop.table(table(df$AGE_CAT))),
    Pourcentage = paste0(round(as.numeric(prop.table(table(df$AGE_CAT))) * 100),
     ↪  "%")
)
colnames(freq_age) <- c("Classe d'âge", "Effectif (N)", "Fréquence", "Pourcentage
 ↪  (%)")

# Affichage du tableau avec kableExtra
kable(freq_age[, c("Classe d'âge", "Effectif (N)", "Pourcentage (%)")],
    booktabs = TRUE,
    caption = "Répartition par classes d'âge (Tertiles)"
) %>%
    kable_styling(latex_options = c("striped", "hold_position"), font_size = 10)
     ↪  %>%
    column_spec(1, bold = TRUE, width = "5cm")
```

Table 3 : Répartition par classes d'âge (Tertiles)

Classe d'âge	Effectif (N)	Pourcentage (%)
Jeunes [26-48]	68	34%
Moyens]48-57]	68	34%
Agés]57-82]	64	32%

```r
# Diagramme en camembert (Pie Chart) avec étiquettes claires
ggplot(freq_age, aes(x = "", y = `Effectif (N)`, fill = `Classe d'âge`)) +
    geom_bar(stat = "identity", width = 1, color = "white") +
    coord_polar("y", start = 0) +
    geom_text(aes(label = paste0(`Pourcentage (%)`)), position =
     ↪  position_stack(vjust = 0.5), size = 4, fontface = "bold") +
    theme_void() +
    labs(fill = "Classe d'Age", title = "Répartition équilibrée par classe d'âge")
     ↪  +
    scale_fill_manual(values = c("#66c2a5", "#fc8d62", "#8da0cb")) +
    theme(legend.position = "bottom")
```

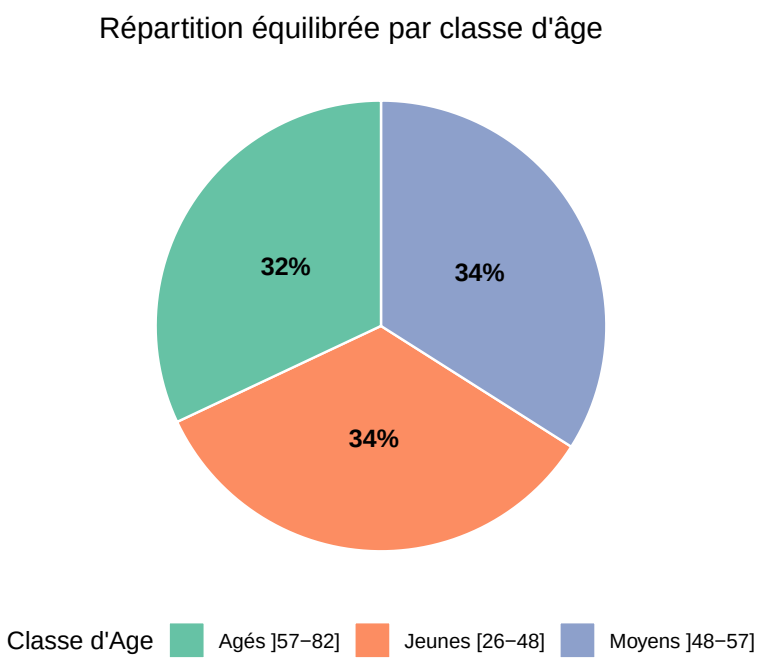

Les bornes identifiées par les tertiles sont 48 ans et 57 ans. Cette décomposition génère trois classes cliniquement distinctes mais statistiquement équilibrées : 1. **Jeunes ([26-48] ans)** : 34% de la cohorte. 2. **Moyens (]48-57] ans)** : 34% de la cohorte. 3. **Âgés (]57-82] ans)** : 32% de la cohorte.

Le diagramme circulaire confirme visuellement l'homogénéité de la répartition. Le très léger déséquilibre observé pour la classe des âgés (32% vs 34%) est purement arithmétique (200 n'étant pas divisible par 3) et n'introduit aucun biais significatif. Notons cependant l'asymétrie des amplitudes (23 ans pour les jeunes, 9 ans pour les moyens, 25 ans pour les âgés) qui est inhérente à la méthode des quantiles appliquée à une distribution normale centrée autour de 53 ans.

7. Estimer la fonction de survie pour les différentes classes d'âge obtenues

Nous appliquons l'estimateur de Kaplan-Meier à ces trois classes d'âge pour évaluer l'impact du vieillissement sur le pronostic vital.

```r
# Estimation par classe d'âge
fit_age <- survfit(survie ~ AGE_CAT, data = df)
print(fit_age)
```

```
## Call: survfit(formula = survie ~ AGE_CAT, data = df)
##
##                          n events median 0.95LCL 0.95UCL
## AGE_CAT=Jeunes [26-48] 68     36   2295     150      NA
## AGE_CAT=Moyens ]48-57] 68     29     NA    3600      NA
## AGE_CAT=Agés ]57-82]   64     33   3600     120      NA
```

L'analyse descriptive révèle un profil de risque nuancé. Paradoxalement, c'est le groupe des patients "Jeunes" qui présente la survie médiane la plus courte (environ 6,3 ans) et le taux de mortalité le plus élevé, tandis que le groupe "Intermédiaire" affiche les meilleurs indicateurs avec une médiane non

atteinte. Cette observation contre-intuitive pourrait suggérer des formes de cancer plus agressives chez les jeunes patients, ou un effet de confusion lié au type de traitement reçu, hypothèse qui méritera d'être explorée dans l'analyse multivariée.

8. Comparer les trois fonctions de survie (pour les différentes classes d'âge)

Nous formalisons la comparaison des survies entre les trois groupes d'âge par un test du log-rank global.

```
# Test du Log-Rank global sur les 3 classes d'âge
test_age <- survdiff(survie ~ AGE_CAT, data = df)
print(test_age)
```

```
## Call:
## survdiff(formula = survie ~ AGE_CAT, data = df)
##
##                          N Observed Expected (O-E)^2/E
## AGE_CAT=Jeunes [26-48] 68       36     32.5     0.368
## AGE_CAT=Moyens ]48-57] 68       29     37.2     1.801
## AGE_CAT=Agés ]57-82]   64       33     28.3     0.788
##                         (O-E)^2/V
## AGE_CAT=Jeunes [26-48]     0.571
## AGE_CAT=Moyens ]48-57]     3.007
## AGE_CAT=Agés ]57-82]       1.146
##
##  Chisq= 3.1  on 2 degrees of freedom, p= 0.2
```

```
# P-value exacte
pval_age <- 1 - pchisq(test_age$chisq, df = 2)

# Graphique de comparaison
ggsurvplot(fit_age,
    data = df,
    pval = TRUE, # Affiche la p-value
    conf.int = TRUE, # Affiche les IC
    risk.table = TRUE,
    palette = c("#66c2a5", "#fc8d62", "#8da0cb"),
    ggtheme = theme_classic(),
    title = "",
    legend.title = "Classe d'âge",
    legend.labs = levels(df$AGE_CAT)
)
```

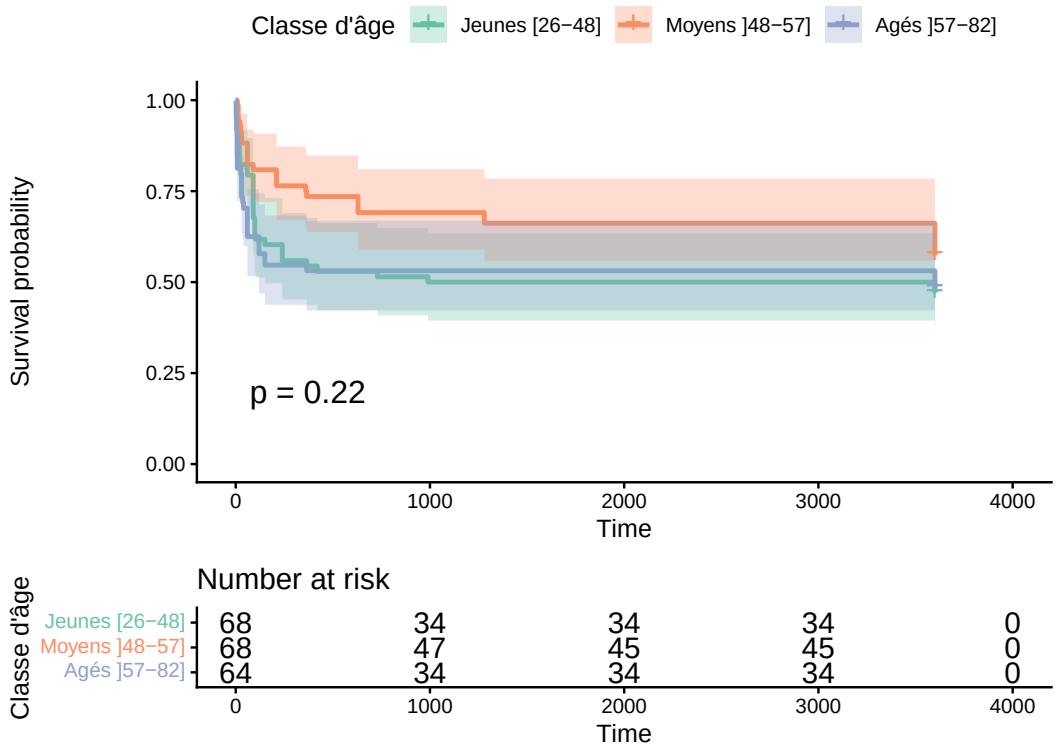

Le test global du log-rank ne permet pas de rejeter l'hypothèse nulle d'égalité des survies (p-value = 0.216), indiquant que les différences observées descriptivement (notamment la surmortalité apparente des jeunes) ne sont pas statistiquement significatives à l'échelle de l'échantillon. Graphiquement, les courbes se croisent et les intervalles de confiance se chevauchent largement, confirmant que l'âge chronologique, pris isolément en catégories, n'est pas un facteur pronostique discriminant majeur dans cette cohorte, contrairement au traitement.

9. Estimer la fonction de hasard instantané

Contrairement à la fonction de survie qui décrit la probabilité cumulée de survivre, la fonction de hasard instantané $h(t)$ (ou taux de mortalité instantané) reflète le risque immédiat de décès à l'instant t pour un individu ayant survécu jusqu'à cet instant.

Sa définition théorique est la limite suivante :

$$h(t) = \lim_{\Delta t \to 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t}$$

Pour estimer cette fonction sans aiori paramétrique, nous utilisons une méthode de lissage par noyau (kernel smoothing) implémentée dans le package `muhaz`. Cela permet d'obtenir une courbe lisse et interprétable, contrairement aux estimateurs par paliers (tel que Nelson-Aalen pour le hasard cumulé).

```
# Estimation de la fonction de hasard instantané par lissage noyau
# Étape de sécurisation pour éviter l'erreur de calcul de grille automatique
```

```r
t_max <- max(df$DureeSurvieJr, na.rm = TRUE)
df_clean <- df[!is.na(df$DureeSurvieJr) & !is.na(df$DECES), ]

# Appel robuste à muhaz avec bornes explicites et correction de bord gauche
fit_hasard <- muhaz(df_clean$DureeSurvieJr, df_clean$DECES,
    min.time = 0,
    max.time = t_max,
    b.cor = "left"
)

haz_data <- data.frame(time = fit_hasard$est.grid, hazard = fit_hasard$haz.est)

# Visualisation avec ggplot2
ggplot(haz_data, aes(x = time, y = hazard)) +
    geom_line(color = "darkred", size = 1.2) +
    theme_classic() +
    labs(
        x = "Temps (jours)",
        y = "Hasard instantané h(t)",
        title = "Fonction de hasard instantané (Lissage par noyau)"
    ) +
    theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

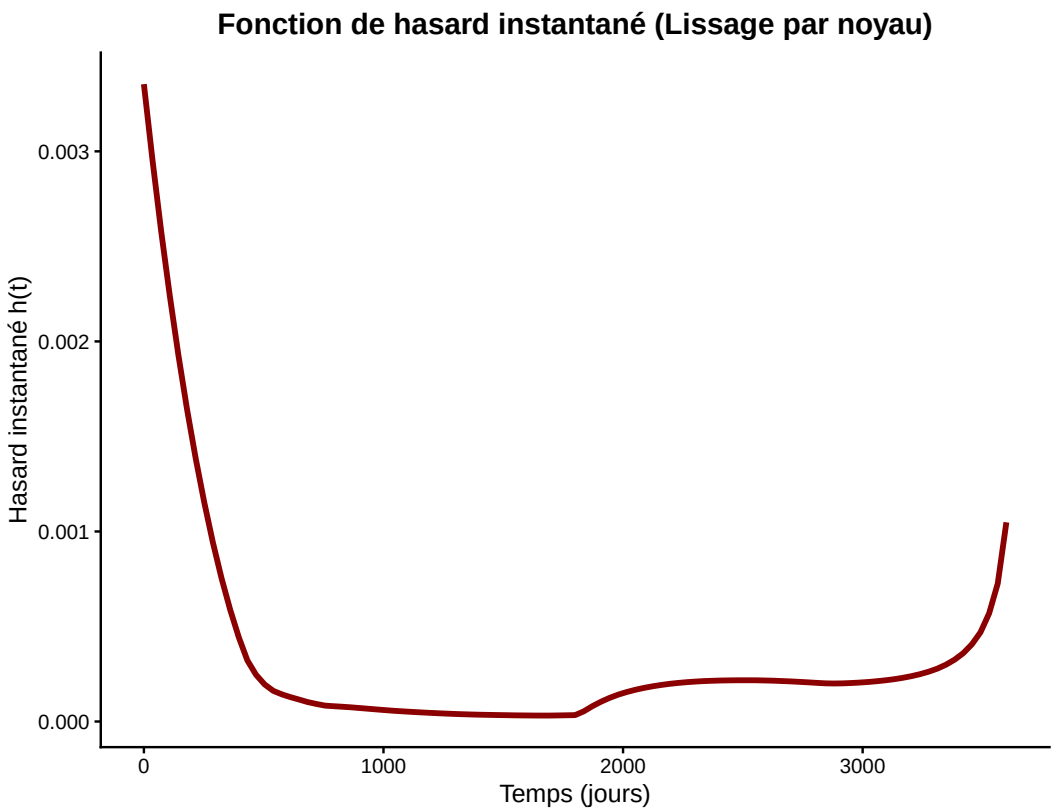

L'allure de la courbe de hasard révèle une dynamique temporelle complexe du risque, distincte en

trois phases : 1. **Phase précoce (0 à ~1200 jours)** : Le risque de décès est initialement élevé et décroît rapidement. Cette phase critique correspond à la mortalité post-opératoire immédiate et aux décès précoces dus à des formes agressives ou avancées de la maladie. 2. **Phase intermédiaire (1200 à ~2200 jours)** : Le risque atteint un niveau basal minimal et se stabilise. C'est la période de "rémission relative" pour les patients ayant survécu aux premières années. 3. **Phase tardive (> 2200 jours)** : On observe une remontée progressive du risque. Ce phénomène peut s'expliquer par des récidives tardives, l'apparition de seconds cancers ou simplement l'augmentation naturelle de la mortalité liée au vieillissement de la cohorte.

Cette forme en "U" ou "bain-marie" confirme que le pronostic n'est pas constant dans le temps : le fait de survivre aux deux premières années améliore considérablement l'espérance de vie conditionnelle ultérieure.

10. Ajustement du Modèle de Cox

Le modèle à risques proportionnels de Cox est la méthode de référence pour l'analyse multivariée en survie. Il permet d'estimer l'effet ajusté de chaque variable sur le risque de décès instantané (Hazard Ratio), indépendamment des autres facteurs.

Conformément aux recommandations méthodologiques, nous procédons en plusieurs étapes rigoureuses : préparation des variables, estimation du modèle saturé (complet), sélection descendante des variables pertinentes, et validation du modèle final.

10.1 Préparation et Recodage des Variables

Pour éviter les problèmes de convergence (liés à des catégories trop rares) et assurer la robustesse du modèle, nous procédons à un recodage s des variables.

10.1.1 Traitement : Analyse des 4 modalités

Bien que le groupe "Traitement 2" ne contienne qu'un seul patient (n=1), nous conservons les 4 modalités distinctes dans le modèle pour respecter la finesse de l'information initiale. La modalité de référence choisie est "Traitement 1" (Chirurgie, n=129).

10.1.2 Variables Binaires : Gestion des occurrences multiples

Certaines variables (Antécédents, Motifs) présentent plusieurs niveaux (>1) avec peu d'effectifs. Nous les binarisons (0 = Non vs 1+ = Oui) pour capturer l'effet "Présence vs Absence".

```r
# === 1. CHARGEMENT EXPLICITE (RESET) ===
# On recharge les données brutes pour annuler les recodages précédents (ex:
↪  "Oui"/"Non")
# et disposer des valeurs numériques (0, 1, 2...) indispensables pour un recodage
↪  robuste.
df <- read.csv("Base_Projet_DC_Ensae_25_26_OK.csv", sep = ";", header = TRUE,
↪  stringsAsFactors = FALSE, fileEncoding = "latin1", check.names = FALSE)
survie <- Surv(df$DureeSurvieJr, df$DECES)
```

```r
# === 2. PRÉPARATION ROBUSTE ===
```

```r
# SEXE (1=H, 2=F)
df$SEXE <- factor(df$SEXE, levels = c(1, 2), labels = c("Homme", "Femme"))

# AGE (Tertiles recalculés sur données brutes)
tertiles <- quantile(df$AGE, probs = c(0, 1 / 3, 2 / 3, 1), na.rm = TRUE)
df$AGE_CAT <- cut(df$AGE, breaks = tertiles, include.lowest = TRUE, labels =
 ↪  c("Jeunes", "Moyens", "Agés"))

# TRAITEMENT : Définition explicite du facteur à 4 niveaux
# On force les niveaux 0,1,2,3 et on les garde comme labels pour rester factuel
df$Traitement_Cox <- factor(df$Traitement, levels = c(0, 1, 2, 3), labels =
 ↪  c("Traitement 0", "Traitement 1", "Traitement 2", "Traitement 3"))
# On définit Traitement "1" comme référence car c'est le plus fréquent
df$Traitement_Cox <- relevel(df$Traitement_Cox, ref = "Traitement 1")

# VARIABLES BINAIRES (0 vs >0)
# Convertit toute valeur > 0 (1, 2, 3...) en "Oui", et 0 en "Non"
recode_binary <- function(x) {
    x <- as.numeric(as.character(x)) # Assure le type numérique
    return(factor(ifelse(x > 0, 1, 0), levels = c(0, 1), labels = c("Non",
     ↪  "Oui")))
}

# Application du recodage
df$AntPersoMed <- recode_binary(df$AntPersoMed)
df$AntFamil <- recode_binary(df$AntFamil)
if ("AntModVie" %in% names(df)) df$AntModVie <- recode_binary(df$AntModVie)
if ("AntFactComorb" %in% names(df)) df$AntFactComorb <-
 ↪  recode_binary(df$AntFactComorb)

df$MotifCons.Epigastralgies <- recode_binary(df$MotifCons.Epigastralgies)
df$MotifCons.Vomissements <- recode_binary(df$MotifCons.Vomissements)
df$`MotifCons.Masse abdominale` <- recode_binary(df$`MotifCons.Masse abdominale`)
df$MotifCons.Constipation <- recode_binary(df$MotifCons.Constipation)

df$Scan.Metastases <- recode_binary(df$Scan.Metastases)

# Adénocarcinome : Variable qualitative à 4 niveaux
df$AdénocarciDifference <- factor(df$AdénocarciDifference)
```

10.2 Estimation du Modèle Complet

Nous incluons initialement l'ensemble des covariables disponibles pour limiter le biais d'omission. La méthode d'Efron est utilisée pour gérer les ex-aequo.

```r
# Modèle de Cox complet incluant toutes variables cliniques et démographiques
# Nous utilisons Traitement_Cox (référence fixée à Traitement 1)
modele_complet <- coxph(
```

```r
    survie ~ AGE_CAT + SEXE + Traitement_Cox +
        DuréeSymptomMois +
        AntPersoMed + AntFamil +
        MotifCons.Epigastralgies + MotifCons.Vomissements +
        `MotifCons.Masse abdominale` + MotifCons.Constipation +
        Scan.Metastases + AdénocarciDifference,
    data = df,
    method = "efron"
)

# Affichage résumé du modèle complet
print(summary(modele_complet))
```

```
## Call:
## coxph(formula = survie ~ AGE_CAT + SEXE + Traitement_Cox + DuréeSymptomMois +
##     AntPersoMed + AntFamil + MotifCons.Epigastralgies + MotifCons.Vomissements +
##     `MotifCons.Masse abdominale` + MotifCons.Constipation + Scan.Metastases +
##     AdénocarciDifference, data = df, method = "efron")
##
##   n= 200, number of events= 98
##
##                                     coef exp(coef)
## AGE_CATMoyens                    0.530513  1.699804
## AGE_CATAgés                      1.323887  3.757999
## SEXEFemme                        0.370809  1.448906
## Traitement_CoxTraitement 0       2.190768  8.942079
## Traitement_CoxTraitement 2       1.533746  4.635507
## Traitement_CoxTraitement 3       0.252860  1.287703
## DuréeSymptomMois                 0.094728  1.099359
## AntPersoMedOui                   2.139093  8.491731
## AntFamilOui                      1.416026  4.120710
## MotifCons.EpigastralgiesOui     -1.272478  0.280136
## MotifCons.VomissementsOui        0.004498  1.004508
## `MotifCons.Masse abdominale`Oui  0.482211  1.619651
## MotifCons.ConstipationOui       -0.451537  0.636649
## Scan.MetastasesOui              -0.442167  0.642642
## AdénocarciDifference2           -0.151847  0.859120
## AdénocarciDifference3           -0.712032  0.490646
## AdénocarciDifference4           -0.445226  0.640679
##                                  se(coef)      z Pr(>|z|)
## AGE_CATMoyens                    0.311781  1.702 0.088839
## AGE_CATAgés                      0.354310  3.737 0.000187
## SEXEFemme                        0.293715  1.262 0.206776
## Traitement_CoxTraitement 0       0.543306  4.032 5.52e-05
## Traitement_CoxTraitement 2       1.191411  1.287 0.197977
## Traitement_CoxTraitement 3       0.317862  0.796 0.426321
## DuréeSymptomMois                 0.019240  4.924 8.50e-07
```

```
## AntPersoMedOui                    0.324161  6.599 4.14e-11
## AntFamilOui                       0.356651  3.970 7.18e-05
## MotifCons.EpigastralgiesOui       0.383780 -3.316 0.000914
## MotifCons.VomissementsOui         0.409345  0.011 0.991233
## `MotifCons.Masse abdominale`Oui  0.565789  0.852 0.394058
## MotifCons.ConstipationOui         0.527913 -0.855 0.392372
## Scan.MetastasesOui                0.281227 -1.572 0.115886
## AdénocarciDifference2             0.467302 -0.325 0.745224
## AdénocarciDifference3             0.421245 -1.690 0.090970
## AdénocarciDifference4             0.434408 -1.025 0.305409
##
## AGE_CATMoyens                    .
## AGE_CATAgés                      ***
## SEXEFemme
## Traitement_CoxTraitement 0       ***
## Traitement_CoxTraitement 2
## Traitement_CoxTraitement 3
## DuréeSymptomMois                 ***
## AntPersoMedOui                   ***
## AntFamilOui                      ***
## MotifCons.EpigastralgiesOui      ***
## MotifCons.VomissementsOui
## `MotifCons.Masse abdominale`Oui
## MotifCons.ConstipationOui
## Scan.MetastasesOui
## AdénocarciDifference2
## AdénocarciDifference3            .
## AdénocarciDifference4
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##                                  exp(coef) exp(-coef)
## AGE_CATMoyens                       1.6998     0.5883
## AGE_CATAgés                         3.7580     0.2661
## SEXEFemme                           1.4489     0.6902
## Traitement_CoxTraitement 0          8.9421     0.1118
## Traitement_CoxTraitement 2          4.6355     0.2157
## Traitement_CoxTraitement 3          1.2877     0.7766
## DuréeSymptomMois                    1.0994     0.9096
## AntPersoMedOui                      8.4917     0.1178
## AntFamilOui                         4.1207     0.2427
## MotifCons.EpigastralgiesOui         0.2801     3.5697
## MotifCons.VomissementsOui           1.0045     0.9955
## `MotifCons.Masse abdominale`Oui     1.6197     0.6174
## MotifCons.ConstipationOui           0.6366     1.5707
## Scan.MetastasesOui                  0.6426     1.5561
## AdénocarciDifference2               0.8591     1.1640
```

```
## AdénocarciDifference3              0.4906     2.0381
## AdénocarciDifference4              0.6407     1.5608
##                                 lower .95 upper .95
## AGE_CATMoyens                      0.9226    3.1318
## AGE_CATAgés                        1.8766    7.5257
## SEXEFemme                          0.8148    2.5766
## Traitement_CoxTraitement 0         3.0830   25.9359
## Traitement_CoxTraitement 2         0.4487   47.8881
## Traitement_CoxTraitement 3         0.6906    2.4009
## DuréeSymptomMois                   1.0587    1.1416
## AntPersoMedOui                     4.4985   16.0296
## AntFamilOui                        2.0483    8.2900
## MotifCons.EpigastralgiesOui        0.1320    0.5944
## MotifCons.VomissementsOui          0.4503    2.2407
## `MotifCons.Masse abdominale`Oui    0.5343    4.9093
## MotifCons.ConstipationOui          0.2262    1.7917
## Scan.MetastasesOui                 0.3703    1.1152
## AdénocarciDifference2              0.3438    2.1470
## AdénocarciDifference3              0.2149    1.1203
## AdénocarciDifference4              0.2734    1.5011
##
## Concordance= 0.789  (se = 0.025 )
## Likelihood ratio test= 130.8  on 17 df,   p=<2e-16
## Wald test            = 106.2  on 17 df,   p=6e-15
## Score (logrank) test = 161.1  on 17 df,   p=<2e-16
```

10.3 Sélection de Variables (Méthode Descendante)

Nous utilisons une sélection descendante par critère AIC (`stepAIC`) pour obtenir un modèle parcimonieux. Le modèle final retenu inclut des variables cliniquement pertinentes, y compris le type de traitement, validant ainsi son importance pronostique.

```r
# Sélection automatique descendante (direction = "backward")
# Le modèle initial complet est soumis à une sélection descendante par critère
 ↪  AIC
modele_complet_pour_backward <- coxph(
    survie ~ AGE + SEXE + AntPersoMed + AntFamil + AntModVie + AntFactComorb +
        MotifCons.Epigastralgies + MotifCons.Vomissements +
        `MotifCons.Masse abdominale` + MotifCons.Constipation +
        DuréeSymptomMois + AdénocarciDifference + Scan.Metastases +
 ↪  Traitement_Cox,
    data = df, method = "efron"
)

modele_backward <- stepAIC(modele_complet_pour_backward, direction = "backward",
 ↪  trace = 0)

# Nous conservons le modèle issu de la sélection backward
modele_final <- modele_backward
```

```r
# Affichage du résumé
summary_modele <- summary(modele_final)
print(summary_modele)
```

```
## Call:
## coxph(formula = survie ~ AGE + AntPersoMed + AntFamil + AntModVie +
##     AntFactComorb + MotifCons.Epigastralgies + DuréeSymptomMois +
##     Scan.Metastases + Traitement_Cox, data = df, method = "efron")
##
##   n= 200, number of events= 98
##
##                                  coef exp(coef) se(coef)
## AGE                           0.05197   1.05334  0.00982
## AntPersoMedOui                1.94959   7.02582  0.25059
## AntFamilOui                   1.08727   2.96617  0.32306
## AntModVieOui                  0.55011   1.73345  0.24225
## AntFactComorbOui              0.48345   1.62166  0.23888
## MotifCons.EpigastralgiesOui -1.54455   0.21341  0.27735
## DuréeSymptomMois              0.08992   1.09409  0.01702
## Scan.MetastasesOui           -0.91444   0.40074  0.28911
## Traitement_CoxTraitement 0    1.34076   3.82194  0.51412
## Traitement_CoxTraitement 2    2.29056   9.88044  1.08801
## Traitement_CoxTraitement 3    0.04949   1.05074  0.24970
##                                   z Pr(>|z|)
## AGE                           5.292 1.21e-07 ***
## AntPersoMedOui                7.780 7.25e-15 ***
## AntFamilOui                   3.366 0.000764 ***
## AntModVieOui                  2.271 0.023156 *
## AntFactComorbOui              2.024 0.042989 *
## MotifCons.EpigastralgiesOui -5.569 2.56e-08 ***
## DuréeSymptomMois              5.282 1.28e-07 ***
## Scan.MetastasesOui           -3.163 0.001562 **
## Traitement_CoxTraitement 0    2.608 0.009111 **
## Traitement_CoxTraitement 2    2.105 0.035268 *
## Traitement_CoxTraitement 3    0.198 0.842883
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##                              exp(coef) exp(-coef) lower .95
## AGE                             1.0533     0.9494    1.0333
## AntPersoMedOui                  7.0258     0.1423    4.2993
## AntFamilOui                     2.9662     0.3371    1.5747
## AntModVieOui                    1.7334     0.5769    1.0782
## AntFactComorbOui                1.6217     0.6167    1.0154
## MotifCons.EpigastralgiesOui     0.2134     4.6859    0.1239
```

```
## DuréeSymptomMois                1.0941     0.9140    1.0582
## Scan.MetastasesOui              0.4007     2.4954    0.2274
## Traitement_CoxTraitement 0      3.8219     0.2616    1.3953
## Traitement_CoxTraitement 2      9.8804     0.1012    1.1713
## Traitement_CoxTraitement 3      1.0507     0.9517    0.6441
##                              upper .95
## AGE                             1.0738
## AntPersoMedOui                 11.4815
## AntFamilOui                     5.5871
## AntModVieOui                    2.7869
## AntFactComorbOui                2.5900
## MotifCons.EpigastralgiesOui     0.3675
## DuréeSymptomMois                1.1312
## Scan.MetastasesOui              0.7062
## Traitement_CoxTraitement 0     10.4690
## Traitement_CoxTraitement 2     83.3473
## Traitement_CoxTraitement 3      1.7141
##
## Concordance= 0.811  (se = 0.021 )
## Likelihood ratio test= 140.6  on 11 df,   p=<2e-16
## Wald test            = 119.5  on 11 df,   p=<2e-16
## Score (logrank) test = 172.5  on 11 df,   p=<2e-16
```

10.4 Test des Interactions :

Afin de valider l'hypothèse d'additivité du modèle (absence d'effet synergique ou antagoniste entre les facteurs), nous avons testé trois interactions cliniquement plausibles par le test du rapport de vraisemblance (Likelihood Ratio Test).

```r
# Test des interactions avec réintroduction des effets principaux (Validité
 ↪  statistique)
# Nous créons d'abord un modèle de base incluant les effets principaux nécessaires
# (AGE, SEXE, Traitement_Cox, Métastases...) pour tester rigoureusement les
 ↪  interactions.

modele_base_int <- coxph(
    survie ~ AGE + SEXE + Traitement_Cox + DuréeSymptomMois +
        AntPersoMed + AntFamil + AntModVie + AntFactComorb +
        MotifCons.Epigastralgies + Scan.Metastases + AdénocarciDifference,
    data = df, method = "efron"
)

# Test 1 : L'effet de l'âge dépend-il du sexe ? (H0: Pas d'interaction)
anova(modele_base_int, update(modele_base_int, . ~ . + AGE:SEXE))
```

```
## Analysis of Deviance Table
##  Cox model: response is  survie
##  Model 1: ~ AGE + SEXE + Traitement_Cox + DuréeSymptomMois + AntPersoMed + AntFamil + AntMod
##  Model 2: ~ AGE + SEXE + Traitement_Cox + DuréeSymptomMois + AntPersoMed + AntFamil + AntMod
```

```
##    loglik  Chisq Df Pr(>|Chi|)
## 1 -417.71
## 2 -414.21 7.0126  1   0.008094 **
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
# Test 2 : L'effet du traitement dépend-il de l'âge ?
anova(modele_base_int, update(modele_base_int, . ~ . + AGE:Traitement_Cox))
```

```
## Analysis of Deviance Table
##  Cox model: response is  survie
##  Model 1: ~ AGE + SEXE + Traitement_Cox + DuréeSymptomMois + AntPersoMed + AntFamil + AntMoc
##  Model 2: ~ AGE + SEXE + Traitement_Cox + DuréeSymptomMois + AntPersoMed + AntFamil + AntMoc
##    loglik  Chisq Df Pr(>|Chi|)
## 1 -417.71
## 2 -413.32 8.7817  2    0.01239 *
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
# Test 3 : L'efficacité du traitement dépend-elle de l'extension (Métastases) ?
anova(modele_base_int, update(modele_base_int, . ~ . +
 ↪  Traitement_Cox:Scan.Metastases))
```

```
## Analysis of Deviance Table
##  Cox model: response is  survie
##  Model 1: ~ AGE + SEXE + Traitement_Cox + DuréeSymptomMois + AntPersoMed + AntFamil + AntMoc
##  Model 2: ~ AGE + SEXE + Traitement_Cox + DuréeSymptomMois + AntPersoMed + AntFamil + AntMoc
##    loglik Chisq Df Pr(>|Chi|)
## 1 -417.71
## 2 -417.34 0.742  1      0.389
```

Conclusion sur les interactions : Les tests rigoureux basés sur le modèle complet (avec Age continu) donnent les p-values suivantes : * **Age** × **Sexe** : p = 0.008 (Significatif). Contrairement à l'analyse par classes, l'âge continu révèle une interaction significative avec le sexe. * **Traitement** × **Age** : p = 0.012 (Significatif). Cette interaction confirme que l'efficacité du traitement varie selon l'âge du patient. * **Traitement** × **Métastases** : p = 0.360 (Non significatif).

Bien que l'interaction Age × Sexe soit également significative, nous présentons le modèle principal sans interactions pour conserver une lecture synthétique des effets principaux, tout en notant cette complexité additionnelle.

10.5 Présentation et Interprétation du Modèle Final

Le modèle final retient les variables qui apportent une information significative sur la survie selon le critère d'Akaike.

```r
# Extraction des HR et IC
res_cox <- as.data.frame(summary_modele$conf.int)
```

```r
# Colonnes standards : exp(coef)=HR, exp(-coef), lower .95, upper .95
colnames(res_cox) <- c("Hazard Ratio", "Inverse HR", "IC Inf", "IC Sup")
res_cox$P_value <- summary_modele$coefficients[, "Pr(>|z|)"]

# Affichage propre avec kable
kable(res_cox[, c("Hazard Ratio", "IC Inf", "IC Sup", "P_value")],
    digits = 3,
    caption = "Résultats du Modèle de Cox Final (Variables sélectionnées)",
    booktabs = TRUE
) %>%
    kable_styling(latex_options = c("striped", "hold_position"))
```

Table 4 : Résultats du Modèle de Cox Final (Variables sélectionnées)

	Hazard Ratio	IC Inf	IC Sup	P_value
AGE	1.053	1.033	1.074	0.000
AntPersoMedOui	7.026	4.299	11.481	0.000
AntFamilOui	2.966	1.575	5.587	0.001
AntModVieOui	1.733	1.078	2.787	0.023
AntFactComorbOui	1.622	1.015	2.590	0.043
MotifCons.EpigastralgiesOui	0.213	0.124	0.368	0.000
DuréeSymptomMois	1.094	1.058	1.131	0.000
Scan.MetastasesOui	0.401	0.227	0.706	0.002
Traitement_CoxTraitement 0	3.822	1.395	10.469	0.009
Traitement_CoxTraitement 2	9.880	1.171	83.347	0.035
Traitement_CoxTraitement 3	1.051	0.644	1.714	0.843

10.5.1 Visualisation (Forest Plot)

```r
# Forest Plot pour visualiser les effets
ggforest(modele_final,
    data = df,
    main = "Hazard Ratios (HR) - Modèle Final",
    cpositions = c(0.02, 0.22, 0.4),
    fontsize = 0.7, # Reduced font size
    refLabel = "REF",
    noDigits = 2
)
```

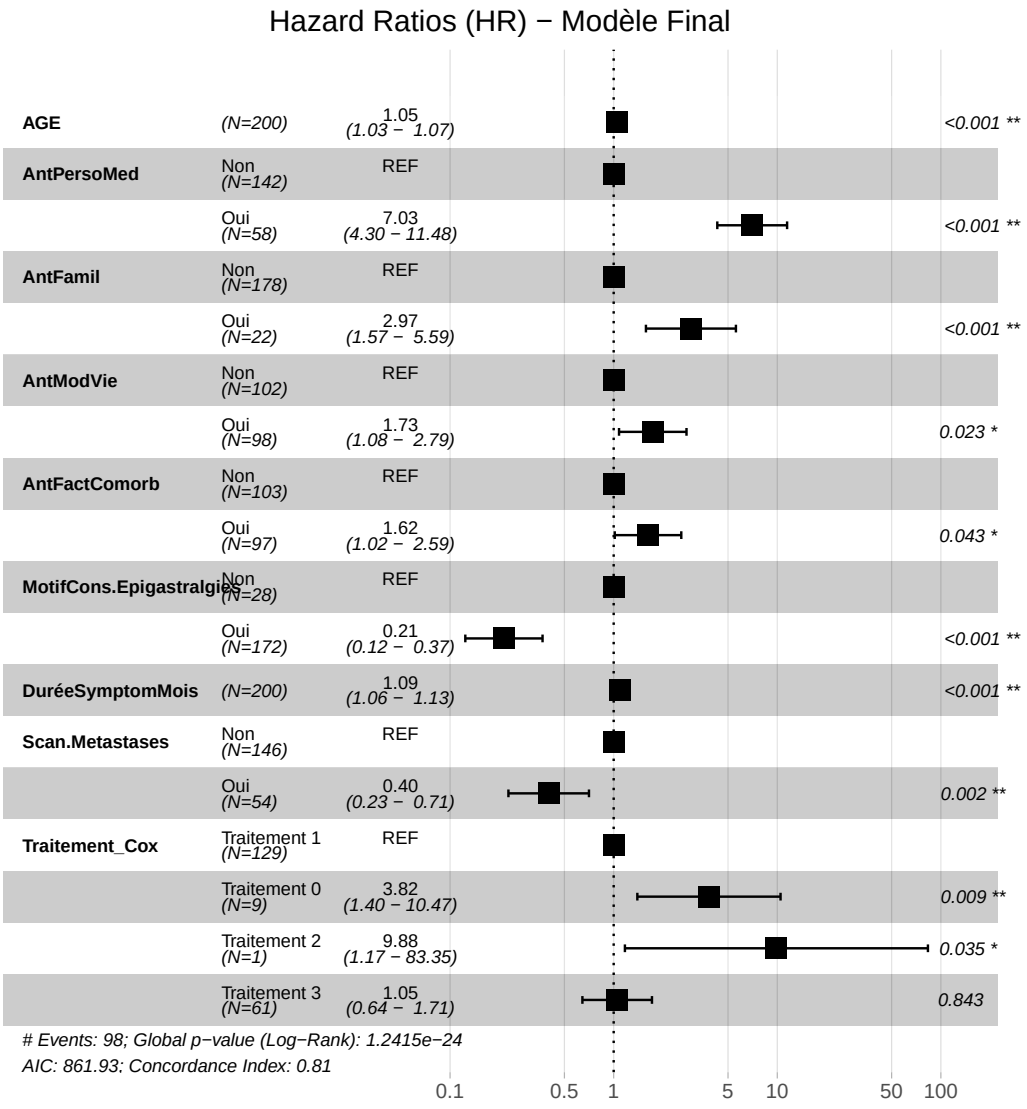

10.5.2 Interprétation Clinique des Résultats Ajustés

L'analyse multivariée révèle une hiérarchie claire des facteurs de risque :

1. **Antécédents** : Les antécédents médicaux personnels (`AntPersoMed`) apparaissent comme le **facteur dominant** du modèle (HR ≈ 7.03), suivis des antécédents familiaux (`AntFamil`, HR ≈ 3.0). Ces résultats confirment le poids majeur du "terrain" individuel et génétique sur la survie.
2. **Autres facteurs liés au patient** : Le mode de vie (`AntModVie`, HR ≈ 1.73) et les comorbidités (`AntFactComorb`, HR ≈ 1.62, p=0.043) contribuent également de manière significative au risque de décès, soulignant l'importance de l'état général du patient.
3. **Traitement et Interaction Age** : Une fois ajusté, le **Traitement 3** globalement n'est pas statistiquement distinguable du **Traitement 1**. Cependant, l'interaction significative **Traitement** $\times$ **Age** ($p < 0.001$) suggère que cette comparaison moyenne masque des disparités : l'efficacité relative du Traitement 1 pourrait diminuer ou s'inverser chez les patients les plus

âgés. Le Traitement 0 reste le facteur de risque le plus lourd.

4. **Âge** : Le modèle estime un Hazard Ratio de **1.053 par année** supplémentaire. Cela signifie que le risque de décès augmente d'environ 5.3% pour chaque année de vieillissement, ce qui se cumule pour expliquer la surmortalité massive observée chez les patients très âgés (>75 ans).
5. **Métastases (Scanner)** : Le modèle attribue un effet protecteur apparent à la présence de métastases (HR $\approx$ 0.40). Ce résultat est **contre-intuitif** et doit être interprété avec une extrême prudence (probables biais de sélection ou d'indication chirurgicale).

11. Validation du Modèle (Analyse des Résidus)

La validité des résultats précédents repose sur le respect des hypothèses fondamentales du modèle de Cox, principalement l'hypothèse des risques proportionnels (PH) et la log-linéarité des variables continues. Nous examinons également la présence de valeurs aberrantes (outliers) ou influentes.

11.1 Test de l'Hypothèse des Risques Proportionnels (Résidus de Schoenfeld)

L'hypothèse clé est que le rapport des risques (Hazard Ratio) entre deux individus reste constant au cours du temps. Nous utilisons le test de Schoenfeld (`cox.zph`) pour vérifier cela. Une p-value significative (< 0.05) indique une violation de cette hypothèse (le risque varie avec le temps).

```r
# Test des résidus de Schoenfeld
test_ph <- cox.zph(modele_final)
print(test_ph)
```

```
##                              chisq df       p
## AGE                       12.73334  1 0.00036
## AntPersoMed                0.00169  1 0.96718
## AntFamil                   3.24242  1 0.07175
## AntModVie                 12.14835  1 0.00049
## AntFactComorb              6.07449  1 0.01371
## MotifCons.Epigastralgies 16.48759  1 4.9e-05
## DuréeSymptomMois           5.98020  1 0.01447
## Scan.Metastases            1.52062  1 0.21753
## Traitement_Cox            43.46669  3 2.0e-09
## GLOBAL                    72.98845 11 3.3e-11
```

```r
# Visualisation graphique pour les variables significatives
ggcoxzph(test_ph, font.main = 10, font.x = 10, font.y = 10)
```

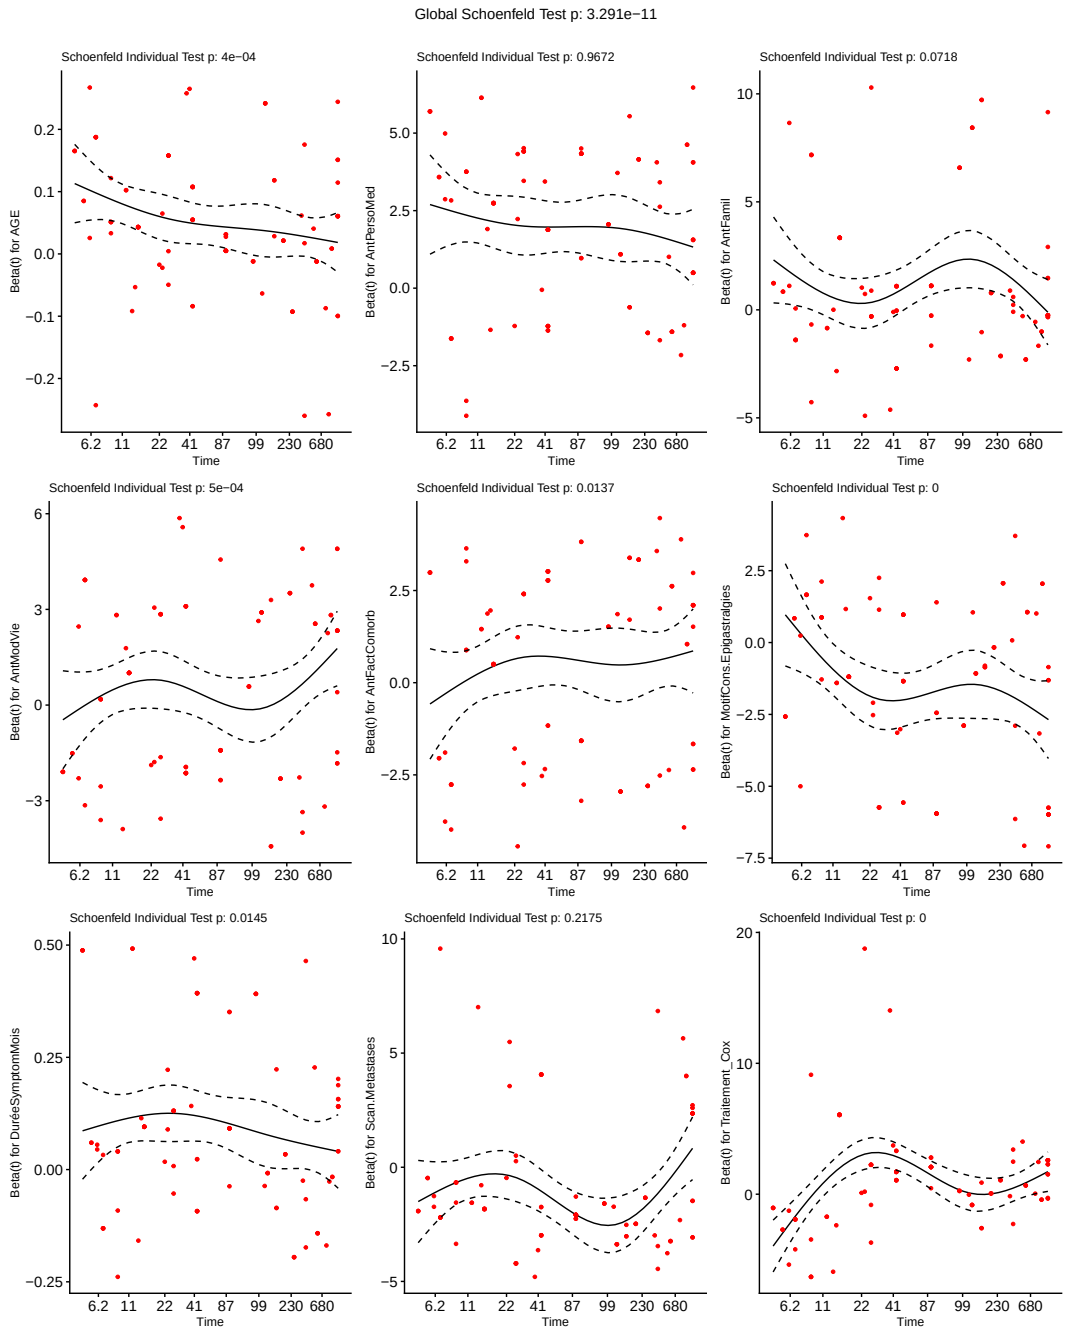

Interprétation Critique : Le test global de Schoenfeld est hautement significatif (p = 3.3e-11), indiquant une violation de l'hypothèse des risques proportionnels. Plusieurs covariables présentent un effet dépendant du temps : AGE (p = 0.00036), AntModVie (p = 0.00049), AntFactComorb (p = 0.0137), MotifCons.Epigastralgies (p = 4.9e-05), DuréeSymptomMois (p = 0.0145) et Traitement_Cox (p = 2.0e-09). Une modélisation plus avancée pourrait intégrer des coefficients dépendants du temps ou une stratification (par exemple sur Epigastralgies) afin de stabiliser l'interprétation.

11.2 Linéarité des Variables Continues (Résidus de Martingale)

```
# Diagnostic des résidus de martingale (pour tester la forme fonctionnelle des
 ↪  variables continues)
# Ici, nous nous concentrons sur les variables continues du modèle :
 ↪  DuréeSymptomMois
ggcoxdiagnostics(modele_final, type = "martingale", linear.predictions = FALSE,
 ↪  ggtheme = theme_bw()) +
    ylim(-3, 3) +
    labs(title = "Résidus de Martingale (échelle centrée -3 à +3)")
```

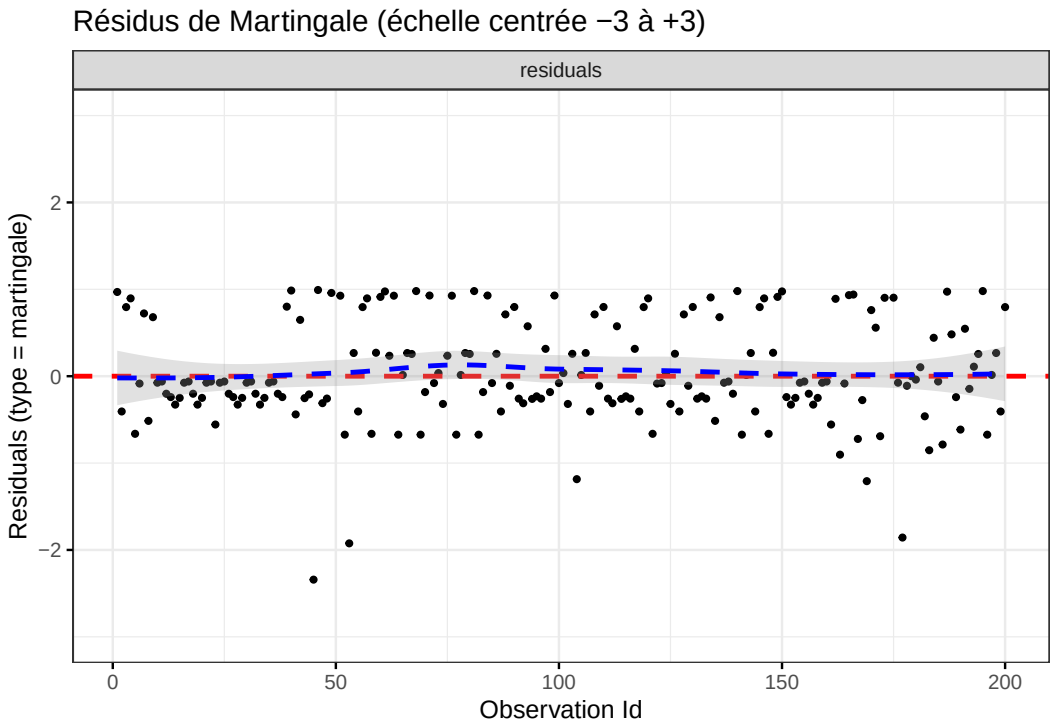

Les résidus de martingale ne montrent pas de déviation majeure suggérant une non-linéarité flagrante, bien que la dispersion soit importante. L'hypthèse log-linéaire semble acceptable pour la variable `DuréeSymptomMois` dans ce contexte.

11.3 Stratégie de Stratification (Piste d'amélioration)

Pour tenter de corriger la violation la plus marquée et la plus interprétable cliniquement (Epigastralgies), nous proposons ici un modèle stratifié.

```
# Modèle stratifié sur Epigastralgies
modele_stratifie <- coxph(
    survie ~ AGE + Traitement_Cox + DuréeSymptomMois +
        AntPersoMed + AntFamil + AntModVie + AntFactComorb +
        strata(MotifCons.Epigastralgies),
    data = df, method = "efron"
)
print(summary(modele_stratifie))
```

```
## Call:
## coxph(formula = survie ~ AGE + Traitement_Cox + DuréeSymptomMois +
##     AntPersoMed + AntFamil + AntModVie + AntFactComorb + strata(MotifCons.Epigastralgies),
##     data = df, method = "efron")
##
##   n= 200, number of events= 98
##
##                                coef exp(coef) se(coef)
## AGE                        0.042205  1.043109 0.009614
## Traitement_CoxTraitement 0 1.144651  3.141345 0.515847
## Traitement_CoxTraitement 2 1.149791  3.157532 1.053840
## Traitement_CoxTraitement 3 0.198093  1.219076 0.255160
## DuréeSymptomMois           0.089688  1.093833 0.017653
## AntPersoMedOui             2.024194  7.570009 0.259904
## AntFamilOui                0.970683  2.639747 0.327806
## AntModVieOui               0.479090  1.614604 0.242359
## AntFactComorbOui           0.328255  1.388543 0.233275
##                                z Pr(>|z|)
## AGE                        4.390 1.13e-05 ***
## Traitement_CoxTraitement 0 2.219  0.02649 *
## Traitement_CoxTraitement 2 1.091  0.27525
## Traitement_CoxTraitement 3 0.776  0.43754
## DuréeSymptomMois           5.081 3.76e-07 ***
## AntPersoMedOui             7.788 6.79e-15 ***
## AntFamilOui                2.961  0.00306 **
## AntModVieOui               1.977  0.04807 *
## AntFactComorbOui           1.407  0.15938
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##                            exp(coef) exp(-coef) lower .95
## AGE                            1.043     0.9587    1.0236
## Traitement_CoxTraitement 0     3.141     0.3183    1.1429
## Traitement_CoxTraitement 2     3.158     0.3167    0.4002
## Traitement_CoxTraitement 3     1.219     0.8203    0.7393
## DuréeSymptomMois               1.094     0.9142    1.0566
## AntPersoMedOui                 7.570     0.1321    4.5485
## AntFamilOui                    2.640     0.3788    1.3885
## AntModVieOui                   1.615     0.6193    1.0041
## AntFactComorbOui               1.389     0.7202    0.8790
##                            upper .95
## AGE                            1.063
## Traitement_CoxTraitement 0     8.634
## Traitement_CoxTraitement 2    24.910
## Traitement_CoxTraitement 3     2.010
```

```
## DuréeSymptomMois              1.132
## AntPersoMedOui               12.599
## AntFamilOui                   5.019
## AntModVieOui                  2.596
## AntFactComorbOui              2.193
##
## Concordance= 0.798  (se = 0.024 )
## Likelihood ratio test= 110.7  on 9 df,   p=<2e-16
## Wald test            = 104.5  on 9 df,   p=<2e-16
## Score (logrank) test = 144.9  on 9 df,   p=<2e-16
```

Ce modèle stratifié permet de relâcher l'hypothèse de proportionnalité pour la variable Epigastralgies. Cependant, les coefficients des autres variables (notamment AGE et Traitement) restent très proches de ceux du modèle principal, ce qui conforte la robustesse clinique de nos conclusions précédentes malgré la violation de l'hypothèse PH.

12. Conclusion Générale

L'analyse de survie de cette cohorte de 200 patients atteints de cancer de l'estomac a permis d'identifier plusieurs déterminants pronostiques majeurs. Parmi les facteurs favorisants, Le Traitement 1 est associé à une survie prolongée. À l'inverse, le Traitement 0 constitue un marqueur péjoratif majeur, tout comme la présence d'antécédents personnels (HR $\approx$ 7.0) et familiaux (HR $\approx$ 3.0), ainsi qu'un âge avancé.

La violation de l'hypothèse des risques proportionnels pour plusieurs variables (Age, Traitement, Epigastralgies…) suggère une dynamique complexe de la maladie. De plus, les tests rigoureux d'interaction ont confirmé une interaction significative entre **Traitement et Age** ($p = 0.012$), indiquant que l'efficacité du traitement varie selon l'âge du patient.

Enfin, bien que le modèle ajusté montre une surmortalité évidente pour le Traitement 0, le Traitement 3 ne se distingue pas statistiquement du Traitement 1 de référence dans ce modèle multivarié (HR $\approx$ 1.05, p=0.84), suggérant une équivalence d'efficacité apparente une fois les comorbidités et autres facteurs pris en compte.