République du Sénégal

Un Peuple - Un But - Une Foi

Agence nationale de la Statistique et de la Démographie

Ecole nationale de la Statistique et de l'Analyse économique

ENTREPRISE RISK MANAGEMENT

Rédigé par :

M. GADO Seman Giovanni Jocelyn

&

M. AWOUTO Koffi Samson

Élèves Ingénieurs statisticiens économistes en 3ème année

Professeur :

M. Youssouf BANCE

Enseignant à l'ENSAE

Table des matières

1 Introduction **3**

2 Préliminaires **3**

3 Exploration de la base 20BAAL-PG_2017_YEAR0.csv **3**
- 3.1 Présentation des variables . . . 4
- 3.2 Quelques statistiques . . . 4
  - 3.2.1 Valeurs manquantes . . . 4
- 3.3 Boxplots des variables quantitatives . . . 5
- 3.4 Histogrammes des variables qualitatives . . . 7
- 3.5 Traitement des valeurs aberrantes . . . 7
- 3.6 Corrélation entre les variables quantitatives . . . 9

4 Exploration de la base 20BAAL-PG_2017_CLAIMS_YEAR0.csv **10**

5 Fusion de deux jeu de données **10**

6 Modélisation **11**
- 6.1 Modélisation de la fréquence . . . 11
- 6.2 Modélisation de la sévérité . . . 13
- 6.3 Implémentation du modèle de Poisson . . . 14
- 6.4 Implémentation du modèle binomiale négative avec régression . . . 15
- 6.5 Implémentation du modèle Gamma . . . 15
- 6.6 Implémentation du modèle log-normal . . . 16

7 Présentation des résultats **17**

8 Détermination des primes sur le jeu de validation **17**
- 8.1 Importation de la base de validation . . . 17
- 8.2 Prédiction de la prime pure et de la prime commerciale . . . 18
- 8.3 Enregistrement de la base TARIFPUR.csv . . . 18
- 8.4 Enregistrement du meilleur modèle . . . 18

9 Conclusion **18**

10 Annexe **20**

1 Introduction

L'assurance non-vie occupe une place essentielle dans la gestion des risques auxquels sont confrontés les particuliers et les entreprises. En échange du paiement d'une prime fixée à l'avance, l'assureur s'engage à indemniser les pertes financières pouvant survenir durant la période de couverture. Dans ce contexte, la détermination d'un tarif adéquat constitue un enjeu majeur pour les compagnies d'assurance, puisqu'elle doit permettre à la fois de couvrir les sinistres futurs, d'assurer la rentabilité de l'assureur et de maintenir l'équité entre les assurés selon leur niveau de risque.

La tarification actuarielle repose ainsi sur l'analyse des caractéristiques des assurés et des contrats afin d'évaluer le risque associé à chaque police d'assurance. Les progrès récents en statistique et en science des données offrent aujourd'hui des outils performants pour modéliser ce risque à travers des approches quantitatives adaptées. Parmi celles-ci, l'approche fréquence–sévérité est largement utilisée en assurance non-vie. Elle consiste à modéliser séparément la fréquence des sinistres, c'est-à-dire le nombre de sinistres observés, et leur sévérité, correspondant au coût des sinistres, avant de combiner ces deux composantes pour obtenir une estimation de la prime pure.

Le présent projet s'inscrit dans cette démarche de tarification actuarielle. À partir des bases de données issues du 3rd Pricing Game, contenant des informations sur 100 000 polices d'assurance ainsi que les sinistres associés, l'objectif est de construire un modèle de tarification performant permettant d'estimer la prime pure des contrats d'assurance. Pour cela, plusieurs modèles de régression adaptés aux données d'assurance seront étudiés et comparés afin d'identifier celui offrant les meilleures performances prédictives.

Dans un premier temps, une analyse exploratoire des données sera réalisée afin de mieux comprendre la structure des variables et les relations existant entre les caractéristiques des contrats et le risque observé. Ensuite, la méthodologie de modélisation sera présentée, notamment les lois statistiques retenues, le choix des variables tarifaires et les critères d'évaluation des modèles. Les résultats obtenus seront enfin analysés et comparés afin de proposer un modèle de tarification pertinent. Ce travail aboutira également à la production d'un tarif en prime pure et au développement d'une application interactive sous R Shiny destinée à faciliter la souscription et le calcul automatique des primes commerciales.

2 Préliminaires

Voici la liste des packages qui ont été utilisés tout au long de ce travail.

```
#Importation_des_packages_nécessaires

library(dplyr)
library(knitr)
library(kableExtra)
library(ggplot2)
library(reshape2)
library(DescTools)
library(MASS)
library(pscl)
```

3 Exploration de la base 20BAAL-PG_2017_YEAR0.csv

3.1 Présentation des variables

```
setwd("C:/Users/ASUS/Desktop/ISE 3/Risk management/Projet")
```

```
base <- read.csv("Data/20BAAL-PG_2017_YEAR0.csv",
                 sep = ",",
                 fileEncoding = "latin1")
```

```
dimensions = dim(base)
cat("La base comporte :",dimensions[1],"observations et",dimensions[2],"variables\n")
```

```
str(base)

summary(base)
```

La base importée dans cette section comporte 10000 observations pour total de 31 variables. Ces variables sont reparties en 15 variables quantitatives et en 16 variables qualitatives. Voici la description des variables :

3.2 Quelques statistiques

Nous allons à présent, faire ressortir quelques statistiques sur nos variables afin d'avoir une idée d'ensemble.

3.2.1 Valeurs manquantes

Aucune de nos variables ne compporte des valeurs manquantes.

```
colSums(is.na(base))
```

```
##          id_year        id_policy         drv_age1     drv_age_lic1
##                0                0                0                0
##         drv_sex1         drv_age2     drv_age_lic2         drv_sex2
##                0                0                0                0
##         drv_drv2        id_client           vh_age           vh_cyl
##                0                0                0                0
##           vh_din          vh_fuel          vh_make         vh_model
##                0                0                0                0
##    vh_sale_begin      vh_sale_end         vh_speed          vh_type
##                0                0                0                0
##         vh_value        vh_weight       id_vehicle        pol_bonus
##                0                0                0                0
##     pol_coverage     pol_duration pol_sit_duration     pol_pay_freq
##                0                0                0                0
##         pol_payd        pol_usage   pol_insee_code
##                0                0                0
```

Dans la suite, nous séparerons notre jeu de données en ***variables quantitatives*** et en ***variables qualitatives*** afin de raliser les graphiques adaptés à chaque type de variable.

```
vars_quant <- names(base)[sapply(base, is.numeric)]
```

Table 1: Description des variables de la base de données

Variable	Type	Description
idclient	Chaîne de caractères	Identifiant unique du client assuré
idvehicle	Chaîne de caractères	Identifiant unique du véhicule assuré
idpolicy	Chaîne de caractères	Identifiant unique de la police d'assurance
idyear	Chaîne de caractères	Année d'observation du contrat
polbonus	Numérique	Coefficient de bonus-malus
pol_coverage	Chaîne de caractères	Type de couverture souscrite
polduration	Entier	Durée totale de la police d'assurance
pol_sitduration	Entier	Durée de la situation actuelle du contrat
polpayfreq	Chaîne de caractères	Fréquence de paiement de la prime
polpayd	Chaîne de caractères	Indicateur de paiement
polusage	Chaîne de caractères	Usage du véhicule
pol_inseecode	Chaîne de caractères	Code géographique de résidence
drvdrv2	Chaîne de caractères	Présence d'un conducteur secondaire
drvage1	Entier	Âge du conducteur principal
drvage2	Entier	Âge du conducteur secondaire
drvsex1	Chaîne de caractères	Sexe du conducteur principal
drvsex2	Chaîne de caractères	Sexe du conducteur secondaire
drvage_lic1	Entier	Ancienneté du permis du conducteur principal
drvage_lic2	Entier	Ancienneté du permis du conducteur secondaire
vhage	Entier	Âge du véhicule
vhcyl	Entier	Cylindrée du véhicule
vhdin	Entier	Puissance DIN du véhicule
vhfuel	Chaîne de caractères	Type de carburant
vhmake	Chaîne de caractères	Marque du véhicule
vhmodel	Chaîne de caractères	Modèle du véhicule
vhsalebegin	Entier	Début de commercialisation du véhicule
vhsaleend	Entier	Fin de commercialisation du véhicule
vhspeed	Entier	Vitesse maximale du véhicule
vhtype	Chaîne de caractères	Type de véhicule
vhvalue	Entier	Valeur du véhicule
vhweight	Entier	Poids du véhicule

```
vars_qual <- names(base)[sapply(base, function(x) is.character(x) | is.factor(x))]
```

3.3 Boxplots des variables quantitatives

Nous allons à présent, nous interesser à la distribution de nous variables quantitatives en utlisant les boîtes à mousatches.

Le boxplot de la variable ***drvage1*** montre que l'âge du conducteur principal est relativement concentré autour d'une médiane située approximativement entre 50 et 55 ans. La dispersion reste modérée, avec un intervalle interquartile relativement réduit, ce qui indique que la majorité des assurés principaux appartiennent à une tranche d'âge moyenne. Quelques valeurs extrêmes sont observées pour des âges très élevés, traduisant la présence de conducteurs seniors dans le portefeuille. Cette variable est particulièrement importante en assurance automobile car l'âge du conducteur influence généralement la fréquence des sinistres.

La variable ***drvage_lic1*** présente une distribution relativement étalée avec une médiane autour de 30 à 35 années d'ancienneté du permis. La présence de plusieurs valeurs élevées indique l'existence de conducteurs très expérimentés. L'absence d'asymétrie excessive suggère une population relativement homogène en termes

d'expérience de conduite. Cette variable est pertinente pour la tarification car une ancienneté plus élevée du permis est souvent associée à un risque plus faible.

Le boxplot de ***drvage2*** met en évidence une forte concentration des observations vers les faibles valeurs, avec une médiane proche de zéro. Cela traduit probablement l'absence fréquente de conducteur secondaire dans de nombreux contrats. La présence de quelques valeurs élevées correspond aux contrats comportant effectivement un second conducteur. La distribution est donc fortement asymétrique à droite.

La variable ***drvage_lic2*** présente également une forte asymétrie à droite avec une majorité de valeurs nulles ou faibles, confirmant l'absence fréquente de conducteur secondaire. Plusieurs valeurs atypiques élevées apparaissent cependant, représentant des conducteurs secondaires expérimentés.

Le boxplot de ***vhage*** montre que la majorité des véhicules assurés sont relativement récents, avec une médiane faible située autour de 6 à 8 ans. On observe néanmoins de nombreux véhicules anciens représentés par des valeurs extrêmes supérieures. La distribution est asymétrique à droite, ce qui est fréquent dans les portefeuilles automobiles. L'âge du véhicule constitue un facteur tarifaire important puisqu'il influence à la fois la probabilité de sinistre et le coût des réparations.

La variable ***vhcyl*** présente une dispersion relativement importante avec plusieurs valeurs extrêmes élevées correspondant à des véhicules de forte cylindrée. La majorité des véhicules semble toutefois concentrée autour de cylindrées moyennes. Cette asymétrie suggère l'existence de segments de véhicules très différents dans le portefeuille. La cylindrée étant souvent liée à la puissance du véhicule, elle peut avoir un impact significatif sur le niveau de risque.

Le boxplot de ***vhdin*** révèle une distribution asymétrique avec plusieurs observations extrêmes correspondant à des véhicules très puissants. La majorité des contrats concerne cependant des véhicules de puissance modérée. Cette variable est généralement fortement corrélée au comportement de conduite et au coût potentiel des sinistres, ce qui en fait une variable explicative pertinente dans les modèles de tarification.

La variable ***vhsalebegin*** montre une forte concentration autour des années récentes, traduisant une prédominance de modèles relativement modernes dans le portefeuille. Quelques valeurs plus anciennes apparaissent comme atypiques. Cette variable peut indirectement renseigner sur la génération technologique du véhicule et donc sur son niveau de sécurité.

Le boxplot de ***vhsaleend*** présente un comportement similaire à celui de ***vhsalebegin***, avec une majorité de véhicules appartenant à des modèles récents. La présence de valeurs extrêmes traduit toutefois certains modèles plus anciens encore assurés. Cette variable peut permettre de distinguer les véhicules récents des modèles obsolètes.

La variable ***vhspeed*** présente une dispersion modérée autour d'une médiane située approximativement entre 150 et 170 km/h. Plusieurs valeurs atypiques élevées sont observées pour des véhicules très rapides. Cette variable est particulièrement intéressante du point de vue actuariel puisque les véhicules à vitesse maximale élevée peuvent être associés à une conduite plus risquée et donc à une fréquence de sinistre plus importante.

Le boxplot de ***vhvalue*** met en évidence une distribution fortement asymétrique à droite avec de nombreuses valeurs extrêmes élevées. La majorité des véhicules possède une valeur relativement modérée, tandis qu'une minorité de véhicules haut de gamme entraîne une forte dispersion. Cette variable est essentielle dans la modélisation de la sévérité des sinistres car le coût des réparations dépend fortement de la valeur du véhicule.

La variable ***vhweight*** présente une dispersion relativement modérée avec une médiane autour de 1200–1400 kg. Quelques valeurs extrêmes correspondent à des véhicules particulièrement lourds ou légers. Le poids du véhicule peut influencer la gravité des accidents ainsi que les coûts associés aux dommages matériels.

Le boxplot de ***polbonus*** montre une très forte asymétrie à droite avec une concentration importante des contrats autour des faibles coefficients de bonus-malus. Plusieurs valeurs extrêmes élevées apparaissent néanmoins, traduisant des assurés ayant un historique de sinistres défavorable. Cette variable est centrale dans la tarification automobile puisqu'elle reflète directement le comportement passé de l'assuré.

La variable ***polduration*** présente une dispersion modérée avec une médiane relativement élevée, indiquant que la majorité des contrats possède une durée importante. Peu de valeurs extrêmes sont observées. Cette

stabilité suggère une certaine homogénéité dans les durées de couverture des contrats étudiés.

Le boxplot de ***pol_sitduration*** met en évidence une forte concentration des observations autour de faibles durées, accompagnée de nombreuses valeurs extrêmes élevées. Cela indique que de nombreux contrats ont récemment changé de situation contractuelle tandis que certains contrats présentent une ancienneté importante. Cette variable peut refléter la stabilité du portefeuille et le comportement des assurés.

(Cf la première figure de l'annexe)

3.4 Histogrammes des variables qualitatives

En ce qui concernent les variables qualitatives, nous utliserons des histogrammes afin de faire ressortir les proportions par modalité pour chaque variable.

La variable ***drv_sex1*** montre une répartition relativement déséquilibrée entre les sexes des conducteurs principaux. Les hommes représentent environ 60 % des assurés tandis que les femmes constituent près de 40 % du portefeuille.

La variable ***drv_sex2*** présente une forte proportion d'observations correspondant à l'absence de conducteur secondaire, représentée par la modalité dominante. Parmi les contrats disposant d'un second conducteur, les hommes semblent plus représentés que les femmes. Cette distribution confirme que la majorité des contrats sont souscrits avec un conducteur unique.

La variable ***drv_drv2*** indique qu'environ 70 % des contrats ne comportent pas de conducteur secondaire contre près de 30 % qui en possèdent un. Cette variable montre donc un certain déséquilibre mais reste suffisamment informative. La présence d'un second conducteur pourrait modifier l'exposition au risque et influencer la fréquence des sinistres.

La variable ***vh_fuel*** met en évidence une domination des véhicules utilisant les carburants les plus courants, à savoir le gasoil et le diesel.

La quasi-totalité des véhicules sont utilisées pour des activités de tourisme.

(Cf la deuxième figure de l'annexe)

3.5 Traitement des valeurs aberrantes

Comme vu précédement, nos variables quantitatives présentent des valuers aberrantes. Pour les traiter, nous utiliserons **la winsorisation**. Cette méthode nous permet de ramener toutes les valeurs supérieures à la borne sup au niveau de la borne sup et toutes les valeurs inférieures à la borne inf au niveau de la borne inf.

Nombre de valeurs aberrantes avant traitement :

```
detect_outliers <- function(x) {

  Q1 <- quantile(x, 0.25, na.rm = TRUE)
  Q3 <- quantile(x, 0.75, na.rm = TRUE)

  IQR_value <- IQR(x, na.rm = TRUE)

  lower <- Q1 - 1.5 * IQR_value
  upper <- Q3 + 1.5 * IQR_value

  which(x < lower | x > upper)
}

outliers_summary <- data.frame(
```

```
  Variable = vars_quant,

  Nb_outliers = sapply(vars_quant, function(v)
    length(detect_outliers(base[[v]])))
)

outliers_summary
```

Table 2: Nombre de valeurs aberrantes par variable avant traitement

	Variable	Nb_outliers
drv_age1	drv_age1	4
drv_age_lic1	drv_age_lic1	10
drv_age2	drv_age2	100
drv_age_lic2	drv_age_lic2	9494
vh_age	vh_age	2244
vh_cyl	vh_cyl	2711
vh_din	vh_din	2443
vh_sale_begin	vh_sale_begin	2848
vh_sale_end	vh_sale_end	2408
vh_speed	vh_speed	2875
vh_value	vh_value	2926
vh_weight	vh_weight	5358
pol_bonus	pol_bonus	22047
pol_duration	pol_duration	149
pol_sit_duration	pol_sit_duration	6921

Nombre de valeurs aberrantes après traitement :

```
detect_outliers <- function(x) {

  Q1 <- quantile(x, 0.25, na.rm = TRUE)
  Q3 <- quantile(x, 0.75, na.rm = TRUE)

  IQR_value <- IQR(x, na.rm = TRUE)

  lower <- Q1 - 1.5 * IQR_value
  upper <- Q3 + 1.5 * IQR_value

  which(x < lower | x > upper)
}

outliers_summary <- data.frame(

  Variable = vars_quant,

  Nb_outliers = sapply(vars_quant, function(v)
    length(detect_outliers(base[[v]])))
)

outliers_summary
```

Table 3: Nombre de valeurs aberrantes par variable avant traitement

	Variable	Nb_outliers
drv_age1	drv_age1	0
drv_age_lic1	drv_age_lic1	0
drv_age2	drv_age2	0
drv_age_lic2	drv_age_lic2	0
vh_age	vh_age	0
vh_cyl	vh_cyl	0
vh_din	vh_din	0
vh_sale_begin	vh_sale_begin	0
vh_sale_end	vh_sale_end	0
vh_speed	vh_speed	0
vh_value	vh_value	0
vh_weight	vh_weight	0
pol_bonus	pol_bonus	0
pol_duration	pol_duration	0
pol_sit_duration	pol_sit_duration	0

3.6 Corrélation entre les variables quantitatives

Dans cette partie, nous nous interessons aux éventuelles corrélations existantes entre nos variables quantitatives. Pour ce faire, nous allons sortir le tableau de corrélation.

L'analyse de la heatmap des corrélations entre les variables quantitatives permet de mettre en évidence les principales relations linéaires existant au sein du portefeuille.

Concernant les variables relatives aux conducteurs, on observe une corrélation extrêmement forte entre l'âge du conducteur principal ***drvage1*** et l'ancienneté de son permis ***drv_age_lic1***, avec un coefficient proche de 0,99. Une relation similaire apparaît entre l'âge du conducteur secondaire ***drvage2*** et l'ancienneté de son permis ***drv_age_lic2***, avec une corrélation d'environ 0,98. Ces résultats sont cohérents d'un point de vue logique et métier puisque les conducteurs les plus âgés disposent généralement d'une expérience de conduite plus importante. Toutefois, ces variables apportent une information très proche et leur présence simultanée dans un même modèle pourrait nuire à la robustesse des estimations. Dans une optique de simplification et d'interprétation actuarielle, il pourrait être préférable de conserver uniquement l'âge des conducteurs.

Les variables décrivant les caractéristiques techniques des véhicules présentent également plusieurs corrélations importantes. L'âge du véhicule ***vh_age*** est fortement corrélé négativement avec les variables ***vh_sale_begin*** et ***vh_sale_end***, avec des coefficients avoisinant respectivement -0,96 et -0,95. Cela signifie que les véhicules anciens correspondent naturellement à des modèles commercialisés depuis longtemps, tandis que les véhicules récents sont associés à des périodes de commercialisation plus récentes. Ces variables traduisent donc une information temporelle similaire. Dans ce contexte, conserver uniquement l'âge du véhicule semble plus pertinent, car cette variable est plus directement interprétable et plus facilement exploitable dans les modèles de tarification.

Par ailleurs, plusieurs corrélations fortes apparaissent entre les variables liées à la puissance et aux performances des véhicules. La puissance DIN ***vh_din*** présente notamment une forte corrélation avec la valeur du véhicule ***vh_value*** ainsi qu'avec la vitesse maximale ***vh_speed***. De même, la cylindrée ***vh_cyl*** est fortement liée à la puissance du véhicule et à sa valeur marchande. Ces relations traduisent une cohérence mécanique et économique : les véhicules les plus puissants sont généralement plus rapides, plus coûteux et disposent de moteurs plus importants. La variable ***vh_weight*** apparaît également positivement corrélée avec la valeur du véhicule, indiquant que les véhicules plus lourds sont souvent des modèles plus haut de gamme. Ces résultats

suggèrent que plusieurs variables décrivent finalement des dimensions proches du risque automobile. Dans le cadre de la modélisation, il pourrait être judicieux de ne conserver que certaines variables synthétiques ou les plus explicatives afin d'éviter une redondance excessive de l'information.

Enfin, certaines variables telles que ***pol_duration*** et ***pol_sit_duration*** présentent des corrélations relativement faibles avec le reste des variables quantitatives. Cela suggère qu'elles apportent une information complémentaire et indépendante, potentiellement utile dans l'explication du risque assuré.

(Cf la dernière figure de l'annexe)

Par le calcul du V de Cramer sur nos variables qualitatives, nous a permis de conclure qu'elles ne présentent pas de corrélations nécessitant le retrait d'une ou de plusieurs d'entre elles. Elles apportent singulièrement de l'infomation supplémentaire.

4 Exploration de la base 20BAAL-PG_2017_CLAIMS_YEAR0.csv

Cette base permet de regrouper les informations portant sur les coûts et le nombre de sinistres de chaque véhicule.

```
base_2 <- read.csv("Data/20BAAL-PG_2017_CLAIMS_YEAR0.csv",
                   sep = ",",
                   fileEncoding = "latin1")
```

Elle comporte 13286 observations pour un total de 7 variables.

Les variables nécessitant une attention particulière sont ***le nombre de sinistre*** et ***le coût***.

Table 4: Statistiques descriptives des variables de sinistres

Variable	Moyenne	Médiane	Écart.type	Minimum	Maximum
claim_amount	985.54	343.86	4257.93	-994.1	438258.4
claim_nb	1.00	1.00	0.00	1.0	1.0

On s'aperçoit que notre variable ***claim_amount*** comporte des observations négatives. Ces observations étant présentes en faible nombre (**435**) par rapport au nombre d'observations total, elles seront supprimées pour la suite.

```
nb_negatifs <- sum(base_2$claim_amount < 0)

nb_negatifs
```

```
## [1] 435
```

5 Fusion de deux jeu de données

À présent nous allons fusionner les deux bases afin de continuer avec une seule base comportant toute les informations nécessaires à la modélisation de la fréquence et de la sévérité.

```
base_final <- merge(
  base,
  base_2,
  by = c("id_policy", "id_client", "id_vehicle", "id_year"),
  all.x = TRUE
)
```

Il nous faut maintenant vérifier les contrats pour lesquels on n'a pas soit le coût soit le sinistre.

```
sum(is.na(base_final$claim_nb))
sum(is.na(base_final$claim_amount))
sum(
  is.na(base_final$claim_nb) &
  is.na(base_final$claim_amount)

)
```

On constate par ailleurs que ces contrats présentent des valeurs manquantes aussi bien pour le coût que pour le sinistre. Par ailleurs, on peut donc supposer que ces contrats n'ont pas eu de sinistre et donc que le coût du sinistre est nul.

```
base_final$claim_nb[is.na(base_final$claim_nb)] = 0
base_final$claim_amount[is.na(base_final$claim_amount)] = 0
```

Notre base finale est à présent prête pour la méthodologie.

6 Modélisation

6.1 Modélisation de la fréquence

Pour modéliser la fréquence, quatre principales familles de modèles ont été vues en cours :

- ***Modèle de Poisson*** :

Soit N_i le nombre annuel de sinistres pour l'assuré i.
On suppose que :

$$N_i \sim \mathcal{P}(\lambda_i)$$

avec :

$$\mathbb{E}(N_i \mid x_i) = \lambda_i$$

On considère un ensemble de p variables exogènes observées pour chaque individu i :

$$x_i = (x_{i,1}, x_{i,2}, \ldots, x_{i,p}), \quad i = 1, \ldots, m$$

Dans le cadre de la régression de Poisson, on relie l'espérance conditionnelle aux variables explicatives via une fonction de lien logarithmique :

$$\lambda_i = \exp(\beta_0 + \beta_1 x_{i,1} + \cdots + \beta_p x_{i,p})$$

En prenant le logarithme, on obtient une forme linéaire :

$$\log(\lambda_i) = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_p x_{i,p}$$

Ce modèle est appelé **modèle log-linéaire de Poisson**.

Si l'assuré i est observé pendant une durée d'exposition E_i, alors :

$$Y_i \sim \mathcal{P}(E_i \lambda_i)$$

On considère alors que :

$$Y_i \mid x_i \sim \mathcal{P}(E_i \lambda_i)$$

avec :

$$\log(\lambda_i) = X_i \beta$$

Ce modèle permet d'expliquer la fréquence des sinistres en fonction des caractéristiques du contrat et de l'assuré.
Les coefficients β mesurent l'effet marginal des variables explicatives sur le logarithme de l'intensité des sinistres.

Le modèle de Poisson constitue une base fondamentale en tarification non-vie, notamment pour l'estimation de la fréquence des sinistres dans le cadre de l'approche fréquence–sévérité.

- ***Modèle Binomiale négative avec régression*** :

Soit N_i le nombre de sinistres de l'assuré i. On suppose :

$$N_i \sim \mathrm{NB}(\mu_i, k)$$

où : - μ_i est l'espérance conditionnelle - $k > 0$ est un paramètre de dispersion

$$\mathbb{E}(N_i) = \mu_i, \quad \mathrm{Var}(N_i) = \mu_i + \frac{\mu_i^2}{k}$$
$$\mathrm{Var}(N_i) > \mathbb{E}(N_i)$$

La fonction de lien logarithmique est utilisée :

$$\log(\mu_i) = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_p x_{i,p}$$

Ce modèle permet de prendre en compte l'hétérogénéité non observée entre assurés, souvent présente en assurance automobile.

- ***Modèle ZIP*** :

Le nombre de sinistres est défini par un modèle à deux régimes :

$$N_i = \begin{cases} 0 & \text{avec probabilité } \pi_i \\ \mathrm{Poisson}(\lambda_i) & \text{avec probabilité } 1 - \pi_i \end{cases}$$

$$\mathbb{P}(N_i = 0) = \pi_i + (1 - \pi_i) e^{-\lambda_i}$$
$$\log(\lambda_i) = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_p x_{i,p}$$

La probabilité d'être dans l'état "toujours zéro" est modélisée par :

$$\mathrm{logit}(\pi_i) = \gamma_0 + \gamma_1 z_{i,1} + \cdots + \gamma_p z_{i,p}$$

Le modèle ZIP distingue les assurés structurellement sans risque actif des assurés suivant un processus de sinistres classique

- ***Modèle ZINB*** :

On suppose :

$$N_i = \begin{cases} 0 & \text{avec probabilité } \pi_i \\ \text{NB}(\mu_i, k) & \text{avec probabilité } 1 - \pi_i \end{cases}$$

$$\log(\mu_i) = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_p x_{i,p}$$
$$\text{logit}(\pi_i) = \gamma_0 + \gamma_1 z_{i,1} + \cdots + \gamma_p z_{i,p}$$

Le modèle ZINB combine la gestion de l'excès de zéros et la prise en compte de la sur-dispersion

6.2 Modélisation de la sévérité

Deux principales familles de modèles ont été vues en cours :

- ***Modèle Gamma*** :

On suppose que la sévérité suit une loi Gamma :

$$S_i \sim \Gamma(\alpha, \beta_i)$$

où : - $\alpha > 0$ est le paramètre de forme - $\beta_i > 0$ est le paramètre de taux (ou inverse de l'échelle)

$$\mathbb{E}(S_i) = \frac{\alpha}{\beta_i}, \quad \text{Var}(S_i) = \frac{\alpha}{\beta_i^2}$$

Dans le cadre d'un modèle de régression, on relie l'espérance conditionnelle aux variables explicatives :

$$\log(\mu_i) = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_p x_{i,p}$$

avec :

$$\mu_i = \mathbb{E}(S_i)$$

- ***Modèle Log-normal*** :

On suppose que le logarithme du coût de sinistre suit une loi normale :

$$\ln(S_i) \sim \mathcal{N}(\mu_i, \sigma^2)$$
$$\mathbb{E}(S_i) = \exp\left(\mu_i + \frac{\sigma^2}{2}\right)$$

On modélise :

$$\ln(S_i) = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_p x_{i,p} + \varepsilon_i$$

avec :

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

- ***Modèle Inverse Gaussienne*** :

On suppose :

$$S_i \sim IG(\mu_i, \lambda)$$

$$\mathbb{E}(S_i) = \mu_i, \quad \text{Var}(S_i) = \frac{\mu_i^3}{\lambda}$$

Dans un cadre GLM :

$$\frac{1}{\mu_i^2} = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_p x_{i,p}$$

ou plus classiquement avec lien log :

$$\log(\mu_i) = X_i \beta$$

6.3 Implémentation du modèle de Poisson

```
model_poisson_full <- glm(
  claim_nb ~

    drv_age1 +
    drv_age2 +
    drv_drv2 +

    vh_age +
    vh_din +
    vh_fuel +
    vh_type +
    vh_weight +

    pol_bonus +
    pol_coverage +
    pol_duration +
    pol_sit_duration +
    pol_pay_freq +
    pol_payd +
    pol_usage,
  family = poisson(link = "log"),
  data = base_final
)

model_poisson_backward <- step(
  model_poisson_full,
  direction = "backward",
  trace = TRUE
)

summary(model_poisson_backward)

AIC(model_poisson_full,
    model_poisson_backward)
```

6.4 Implémentation du modèle binomiale négative avec régression

```
model_nb_full <- glm.nb(

  claim_nb ~

    drv_age1 +
    drv_age2 +
    drv_drv2 +

    vh_age +
    vh_din +
    vh_fuel +
    vh_type +
    vh_weight +

    pol_bonus +
    pol_coverage +
    pol_duration +
    pol_sit_duration +
    pol_pay_freq +
    pol_payd +
    pol_usage,

  data = base_final
)

model_nb_backward <- step(
  model_nb_full,
  direction = "backward",
  trace = TRUE
)

summary(model_nb_backward)

AIC(model_nb_full,
    model_nb_backward)
```

Les deux derniers modèles à savoir les modèles ZIP et ZINB ont été testés mais présentent des problèmes de convergence.

6.5 Implémentation du modèle Gamma

```
data_sev <- base_final %>%

  filter(claim_amount > 0)

model_gamma_full <- glm(

  claim_amount ~

    drv_age1 +
    drv_age2 +
    drv_drv2 +
```

```
    vh_age +
    vh_din +
    vh_fuel +
    vh_type +
    vh_weight +

    pol_bonus +
    pol_coverage +
    pol_duration +
    pol_sit_duration +
    pol_pay_freq +
    pol_payd +
    pol_usage,

  family = Gamma(link = "log"),

  data = data_sev
)


model_gamma_backward <- step(
  model_gamma_full,
  direction = "backward",
  trace = TRUE
)

summary(model_gamma_backward)


AIC(model_gamma_full,
    model_gamma_backward)
```

6.6 Implémentation du modèle log-normal

```
model_lognormal_full <- lm(

  log(claim_amount) ~

    drv_age1 +
    drv_age2 +
    drv_drv2 +

    vh_age +
    vh_din +
    vh_fuel +
    vh_type +
    vh_weight +

    pol_bonus +
    pol_coverage +
    pol_duration +
    pol_sit_duration +
```

```
    pol_pay_freq +
    pol_payd +
    pol_usage,

  data = data_sev
)

model_lognormal_backward <- step(
  model_lognormal_full,
  direction = "backward",
  trace = TRUE
)

summary(model_lognormal_backward)

AIC(model_lognormal_full,
    model_lognormal_backward)
```

La loi inverse gaussienne a également été testée mais malgré plusieurs spécifications on note des problèmes de convergence.

7 Présentation des résultats

Les différents modèles ont été implémentés aussi bien pour la fréquence que pour la sévérité. Pour chaque modèle, la méthode itérative descendante a été appliquée afin de ne se retrouver qu'avec les variables significatives.

Le tableau suivant rensiegne les valeurs obtenues pour l'AIC au niveau des différents modèles :

Table 5: Comparaison des AIC des modèles de fréquence et de sévérité

Modele	AIC
Poisson (complet)	77360.49
Poisson (backward)	77353.86
Binomiale négative (complet)	77363.13
Binomiale négative (backward)	77363.13
Gamma (complet)	200436.12
Gamma (backward)	200450.57
Log-normal (complet)	48062.29
Log-normal (backward)	48045.58

En se basant sur l'AIC, nous retenous comme modèle pour la fréquence ***le modèle de Poisson*** et pour la sévérité ***le modèle log-normal*** car présentant tous deux les AIC plus faibles.

8 Détermination des primes sur le jeu de validation

8.1 Importation de la base de validation

```
valid <- read.csv("Data/20BAAL-PG_2017_YEAR1.csv",
                  sep = ",",
                  fileEncoding = "latin1")
```

8.2 Prédiction de la prime pure et de la prime commerciale

```
pred_freq <- predict(model_poisson_backward,
                     newdata = valid,
                     type = "response")

sigma2 <- summary(model_lognormal_backward)$sigma^2

pred_sev_log <- predict(model_lognormal_backward,
                        newdata = valid)

pred_sev <- exp(pred_sev_log + sigma2 / 2)

prime_pure <- pred_freq * pred_sev

valid$prime_pure <- prime_pure

valid$prime_commerciale <- valid$prime_pure * 1.15
```

8.3 Enregistrement de la base TARIFPUR.csv

```
tarif <- valid %>%
  dplyr::select(id_client,
         id_vehicle,
         id_policy,
         prime_pure = prime_pure,
         prime_commerciale)

write.csv(tarif,
          "Sorties/TARIFPUR.csv",
          row.names = FALSE)
```

8.4 Enregistrement du meilleur modèle

```
save(
  model_poisson_backward,
  model_lognormal_backward,
  sigma2,
  file = "Sorties/models_tarification.RData"
)
```

9 Conclusion

Ce projet de tarification en assurance non-vie a permis de mettre en œuvre une démarche complète de modélisation actuarielle basée sur l'approche fréquence–sévérité. À partir des données issues du 3rd Pricing Game, une analyse exploratoire approfondie a d'abord été réalisée afin de comprendre la structure des variables et les relations existant entre les caractéristiques des assurés, des véhicules et le risque de sinistralité.

Dans un second temps, plusieurs modèles statistiques ont été estimés pour la modélisation de la fréquence des sinistres, notamment les modèles de Poisson, binomial négatif, ZIP et ZINB. La comparaison des critères d'information a conduit à retenir le modèle de Poisson comme le plus pertinent pour décrire la fréquence des sinistres dans notre portefeuille. En parallèle, la sévérité des sinistres a été modélisée à l'aide de différentes

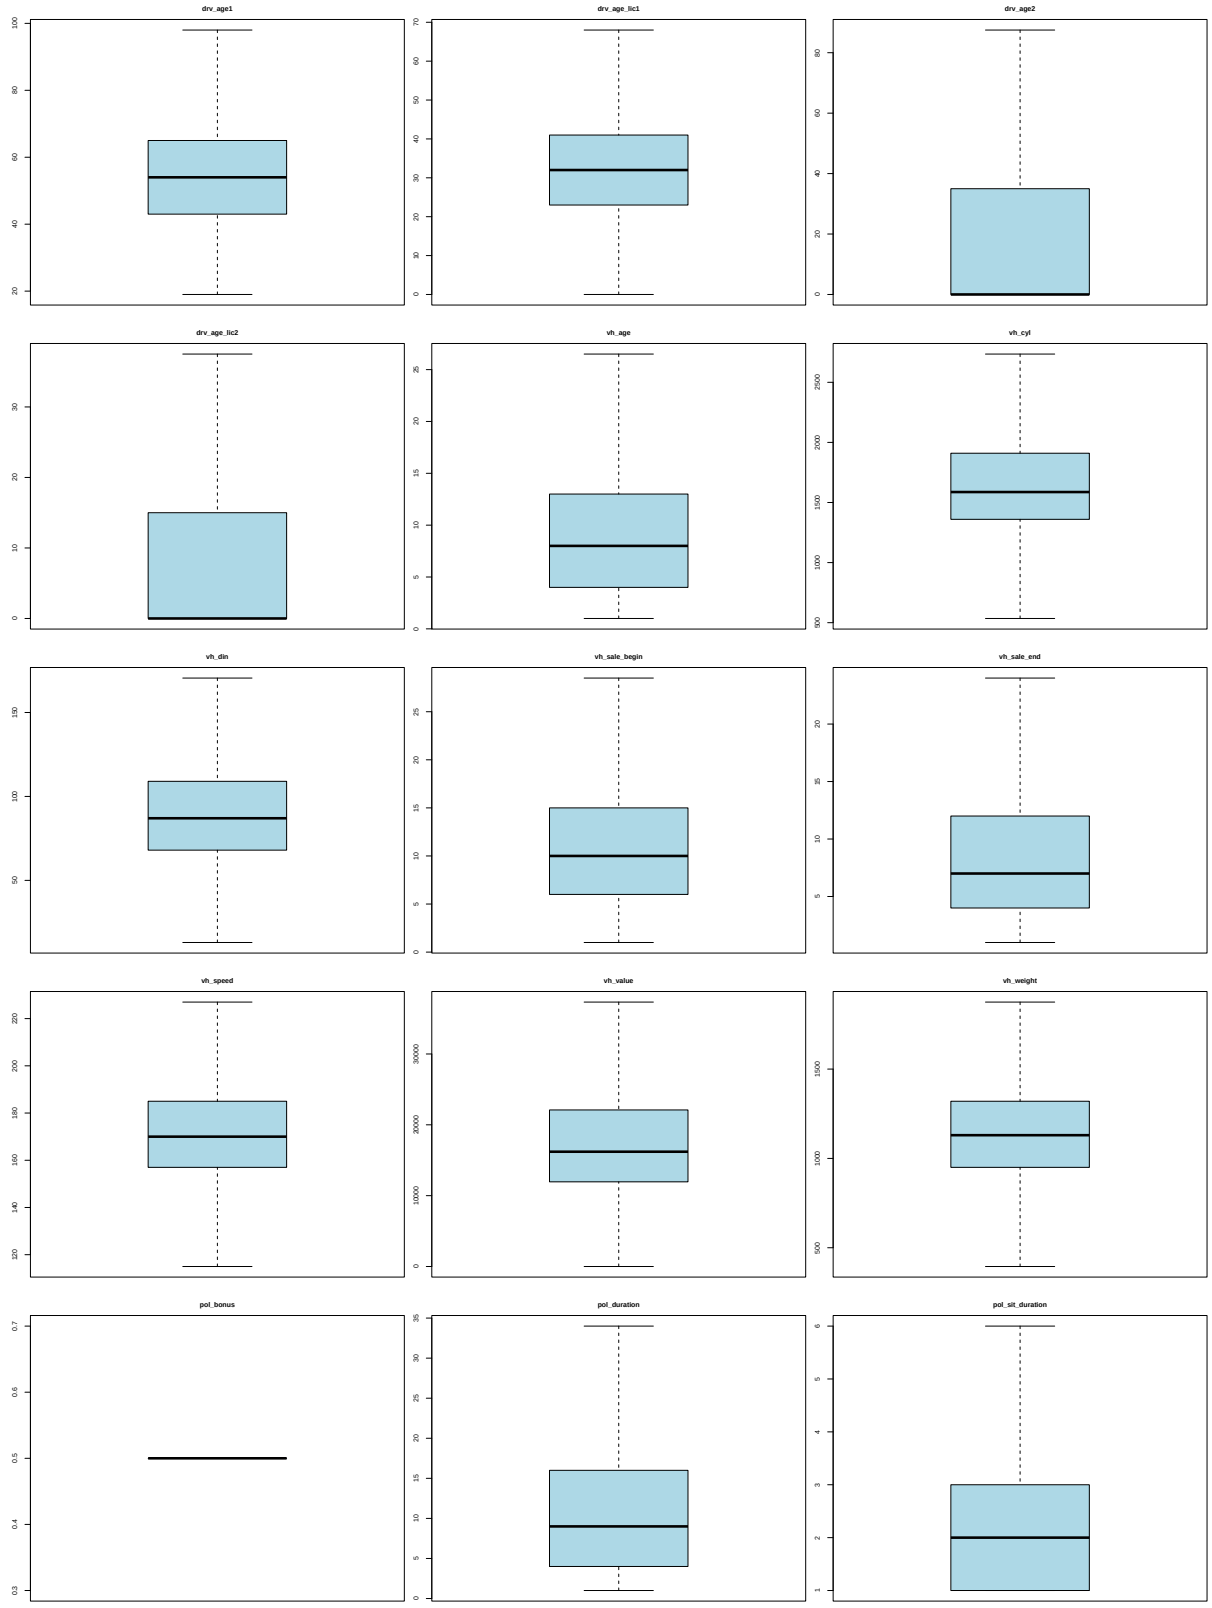
approches, dont les modèles Gamma, log-normal et inverse gaussien. Le modèle log-normal s'est distingué par sa performance et sa stabilité, et a été retenu comme modèle final de sévérité.

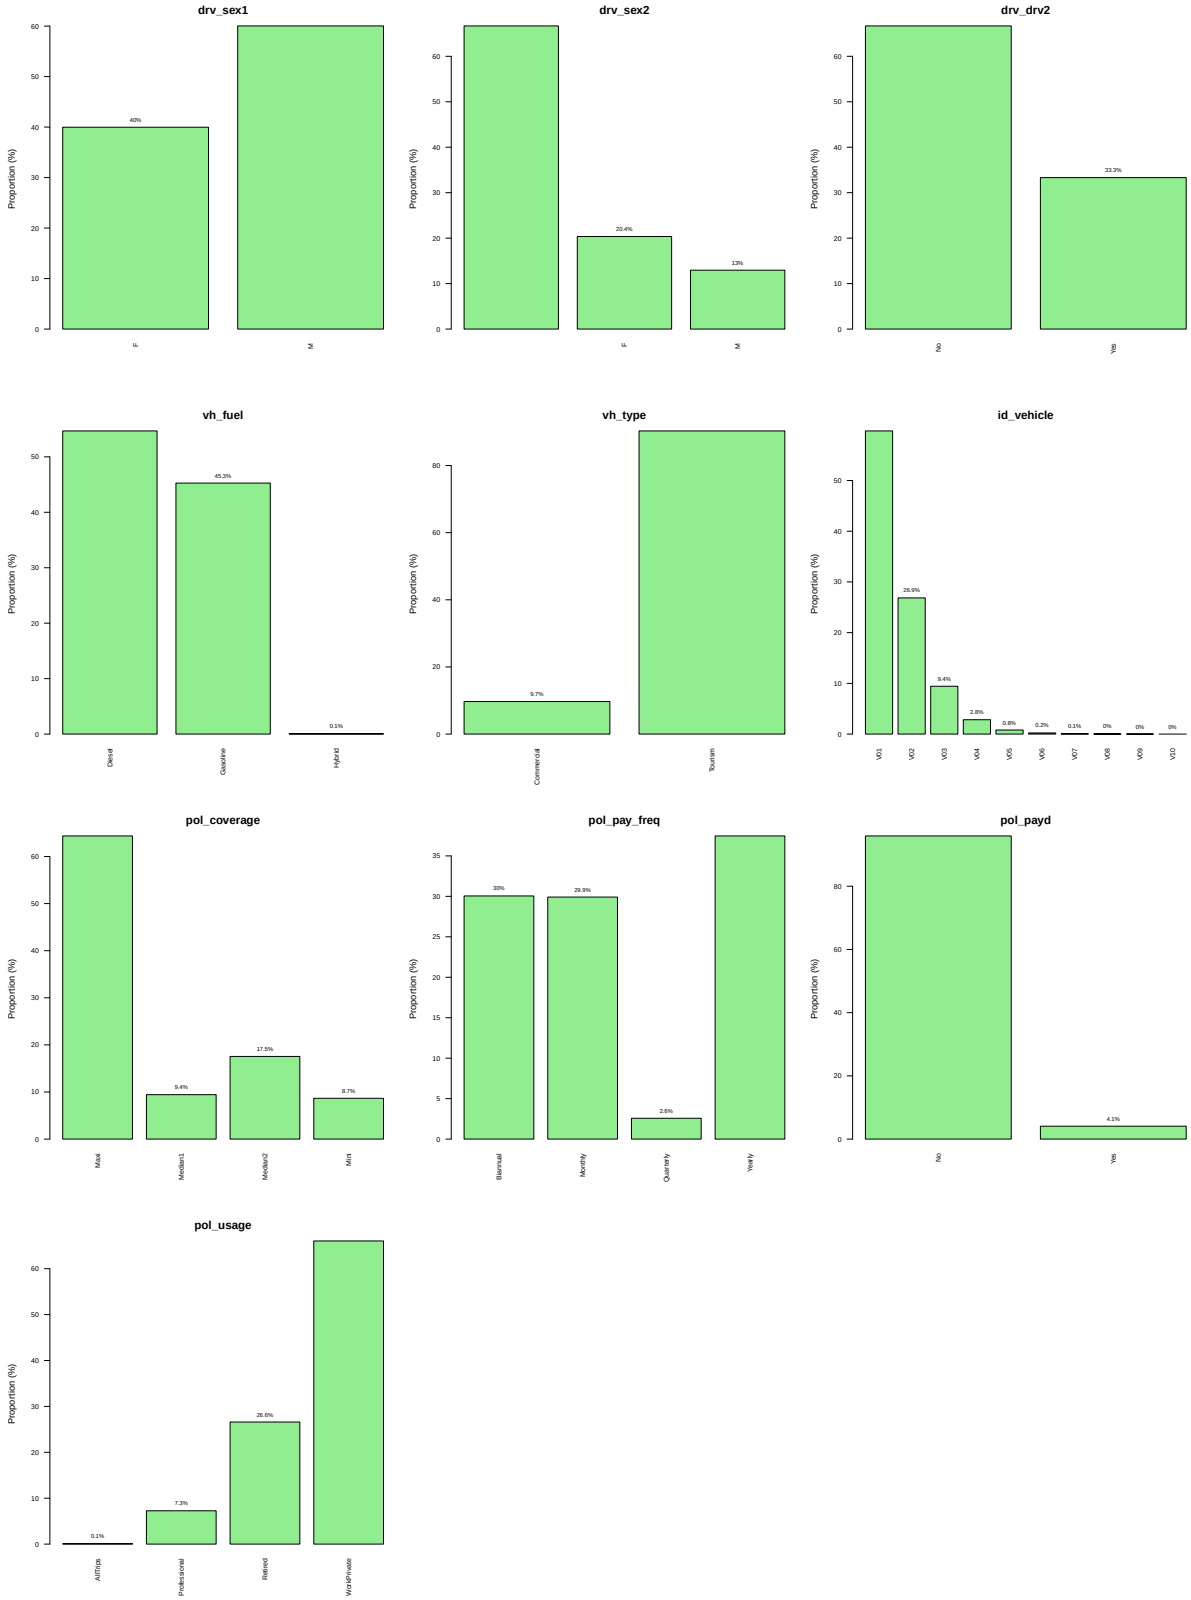
La combinaison de ces deux composantes a permis de construire la prime pure individuelle pour chaque assuré, en multipliant l'espérance du nombre de sinistres par l'espérance du coût moyen d'un sinistre. Une marge de sécurité de 15 % a ensuite été appliquée afin d'obtenir la prime commerciale.

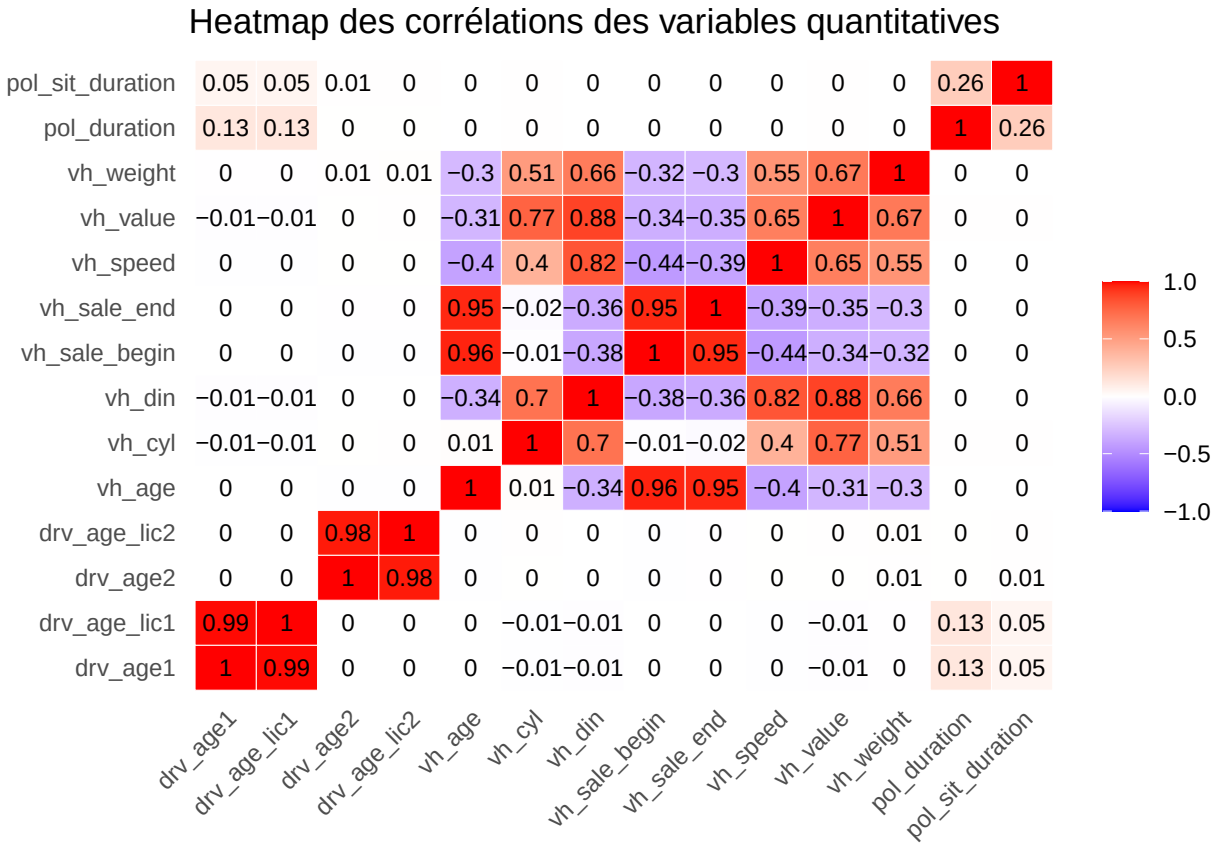
Enfin, le développement d'une application interactive sous R Shiny a permis de rendre le modèle opérationnel et accessible, en offrant un outil de simulation de primes basé sur les caractéristiques de risque saisies par l'utilisateur. Cette application illustre concrètement l'intérêt des modèles actuariels en contexte réel de tarification.

Ce travail met ainsi en évidence la pertinence des méthodes statistiques en assurance non-vie, tout en soulignant l'importance du choix des modèles, de la qualité des données et de leur interprétation actuarielle dans la construction d'un tarif cohérent et robuste.

10 Annexe


drv_age1
drv_age_lic1
drv_age2
drv_age_lic2
vh_age
vh_cyl
vh_din
vh_sale_begin
vh_sale_end
vh_speed
vh_value
vh_weight
pol_bonus
pol_duration
pol_slt_duration


drv_sex1
Proportion (%)
40%
F
M
drv_sex2
Proportion (%)
20.4%
13%
F
M
drv_drv2
Proportion (%)
33.3%
No
Yes
vh_fuel
Proportion (%)
45.3%
0.1%
Diesel
Gasoline
Hybrid
vh_type
Proportion (%)
9.7%
Commercial
Tourism
id_vehicle
Proportion (%)
26.9%
9.4%
2.8%
0.8%
0.2%
0.1%
0%
0%
0%
V01
V02
V03
V04
V05
V06
V07
V08
V09
V10
pol_coverage
Proportion (%)
9.4%
17.5%
8.7%
Most
Median1
Median2
Min
pol_pay_freq
Proportion (%)
30%
29.9%
2.6%
Biannual
Monthly
Quarterly
Yearly
pol_payd
Proportion (%)
4.1%
No
Yes
pol_usage
Proportion (%)
0.1%
7.3%
26.6%
AllTrips
Professional
Retired
WorkPrivate


Heatmap des corrélations des variables quantitatives
pol_sit_duration 0.05 0.05 0.01 0 0 0 0 0 0 0 0 0 0.26 1
pol_duration 0.13 0.13 0 0 0 0 0 0 0 0 0 0 1 0.26
vh_weight 0 0 0.01 0.01 −0.3 0.51 0.66 −0.32 −0.3 0.55 0.67 1 0 0
vh_value −0.01 −0.01 0 0 −0.31 0.77 0.88 −0.34 −0.35 0.65 1 0.67 0 0
vh_speed 0 0 0 0 −0.4 0.4 0.82 −0.44 −0.39 1 0.65 0.55 0 0
vh_sale_end 0 0 0 0 0.95 −0.02 −0.36 0.95 1 −0.39 −0.35 −0.3 0 0
vh_sale_begin 0 0 0 0 0.96 −0.01 −0.38 1 0.95 −0.44 −0.34 −0.32 0 0
vh_din −0.01 −0.01 0 0 −0.34 0.7 1 −0.38 −0.36 0.82 0.88 0.66 0 0
vh_cyl −0.01 −0.01 0 0 0.01 1 0.7 −0.01 −0.02 0.4 0.77 0.51 0 0
vh_age 0 0 0 0 1 0.01 −0.34 0.96 0.95 −0.4 −0.31 −0.3 0 0
drv_age_lic2 0 0 0.98 1 0 0 0 0 0 0 0 0.01 0 0
drv_age2 0 0 1 0.98 0 0 0 0 0 0 0 0.01 0 0.01
drv_age_lic1 0.99 1 0 0 0 −0.01 −0.01 0 0 0 −0.01 0 0.13 0.05
drv_age1 1 0.99 0 0 0 −0.01 −0.01 0 0 0 −0.01 0 0.13 0.05
drv_age1
drv_age_lic1
drv_age2
drv_age_lic2
vh_age
vh_cyl
vh_din
vh_sale_begin
vh_sale_end
vh_speed
vh_value
vh_weight
pol_duration
pol_sit_duration
1.0
0.5
0.0
−0.5
−1.0